

概率论与数理统计 (7)

清华大学

2020 年春季学期

几点回顾

- 切比雪夫不等式：对于任意 $c > 0$, $P(|X - E(X)| \geq c) \leq \frac{1}{c^2} \text{Var}(X)$.
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$.
- 特征函数的在 $t = 0$ 处的泰勒展开：
$$\varphi(t) = 1 + iE(X)t + \frac{1}{2}i^2E(X^2)t^2 + \dots$$
- 依概率收敛与依分布收敛，当极限是常数时，二者等价。
- 如果 X_n 的特征函数 $\varphi_n(t)$ 收敛到 X 的特征函数时， X_n 依分布收敛到 X .
- 若 X 与 Y 相互独立，则 $X + Y$ 的特征函数为
$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t).$$
- $Y = aX + b$, 则 Y 的特征函数为 $\varphi_Y(t) = e^{ibt}\varphi_X(at)$.

泊松定理 (重制版)

- 对于任意的 $n \in \mathbb{N}$, 考虑 n 个独立随机变量 X_{n1}, \dots, X_{nn} ,

$$P(X_{nk} = 1) = p_{nk}, \quad P(X_{nk} = 0) = 1 - p_{nk}.$$

若当 $n \rightarrow \infty$ 时, $\max_{1 \leq k \leq n} p_{nk} \rightarrow 0$, 且 $\sum_{k=1}^n p_{nk} \rightarrow \lambda$, 则若令 $S_n = X_{n1} + \dots + X_{nn}$, 有对于任意 $m = 0, 1, \dots$,

$$P(S_n = m) \rightarrow \frac{\lambda^m}{m!} e^{-\lambda}, \quad n \rightarrow \infty.$$

泊松定理 (重制版)

- 对于任意的 $n \in \mathbb{N}$, 考虑 n 个独立随机变量 X_{n1}, \dots, X_{nn} ,

$$P(X_{nk} = 1) = p_{nk}, \quad P(X_{nk} = 0) = 1 - p_{nk}.$$

若当 $n \rightarrow \infty$ 时, $\max_{1 \leq k \leq n} p_{nk} \rightarrow 0$, 且 $\sum_{k=1}^n p_{nk} \rightarrow \lambda$, 则若令 $S_n = X_{n1} + \dots + X_{nn}$, 有对于任意 $m = 0, 1, \dots$,

$$P(S_n = m) \rightarrow \frac{\lambda^m}{m!} e^{-\lambda}, \quad n \rightarrow \infty.$$

- $\varphi_{S_n}(t) = E(e^{itS_n}) = \prod_{k=1}^n (p_{nk}e^{it} + 1 - p_{nk}) = \prod_{k=1}^n (1 + p_{nk}(e^{it} - 1)),$

泊松定理 (重制版)

- 对于任意的 $n \in \mathbb{N}$, 考虑 n 个独立随机变量 X_{n1}, \dots, X_{nn} ,

$$P(X_{nk} = 1) = p_{nk}, \quad P(X_{nk} = 0) = 1 - p_{nk}.$$

若当 $n \rightarrow \infty$ 时, $\max_{1 \leq k \leq n} p_{nk} \rightarrow 0$, 且 $\sum_{k=1}^n p_{nk} \rightarrow \lambda$, 则若令 $S_n = X_{n1} + \dots + X_{nn}$, 有对于任意 $m = 0, 1, \dots$,

$$P(S_n = m) \rightarrow \frac{\lambda^m}{m!} e^{-\lambda}, \quad n \rightarrow \infty.$$

- $\varphi_{S_n}(t) = E(e^{itS_n}) = \prod_{k=1}^n (p_{nk}e^{it} + 1 - p_{nk}) = \prod_{k=1}^n (1 + p_{nk}(e^{it} - 1))$,
而由条件假设 $Y(n, t) = \prod_{k=1}^n (1 + p_{nk}(e^{it} - 1)) \rightarrow e^{\lambda(e^{it} - 1)}$.

泊松定理 (重制版)

- 对于任意的 $n \in \mathbb{N}$, 考虑 n 个独立随机变量 X_{n1}, \dots, X_{nn} ,

$$P(X_{nk} = 1) = p_{nk}, \quad P(X_{nk} = 0) = 1 - p_{nk}.$$

若当 $n \rightarrow \infty$ 时, $\max_{1 \leq k \leq n} p_{nk} \rightarrow 0$, 且 $\sum_{k=1}^n p_{nk} \rightarrow \lambda$, 则若令 $S_n = X_{n1} + \dots + X_{nn}$, 有对于任意 $m = 0, 1, \dots$,

$$P(S_n = m) \rightarrow \frac{\lambda^m}{m!} e^{-\lambda}, \quad n \rightarrow \infty.$$

- $\varphi_{S_n}(t) = E(e^{itS_n}) = \prod_{k=1}^n (p_{nk}e^{it} + 1 - p_{nk}) = \prod_{k=1}^n (1 + p_{nk}(e^{it} - 1))$,
而由条件假设 $Y(n, t) = \prod_{k=1}^n (1 + p_{nk}(e^{it} - 1)) \rightarrow e^{\lambda(e^{it} - 1)}$.

$$\ln Y(n, t) = \sum_{k=1}^n \ln(1 + p_{nk}(e^{it} - 1)) = \sum_{k=1}^n p_{nk}(e^{it} - 1) + O\left(\sum_{k=1}^n p_{nk}^2\right).$$

大数定律

- (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为每次试验中 A 发生的概率, 则对任意的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\frac{S_n}{n} - p| < \epsilon) = 1.$$

大数定律

- (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为每次试验中 A 发生的概率, 则对任意的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\frac{S_n}{n} - p| < \epsilon) = 1.$$

也就是说 $\frac{S_n}{n} \xrightarrow{P} p$.

大数定律

- (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为每次试验中 A 发生的概率, 则对任意的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\frac{S_n}{n} - p| < \epsilon) = 1.$$

也就是说 $\frac{S_n}{n} \xrightarrow{P} p$.

- $S_n \sim b(n, p)$, $E(\frac{S_n}{n}) = p$, $Var(\frac{S_n}{n}) = \frac{p(1-p)}{n}$.

大数定律

- (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为每次试验中 A 发生的概率, 则对任意的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\frac{S_n}{n} - p| < \epsilon) = 1.$$

也就是说 $\frac{S_n}{n} \xrightarrow{P} p$.

- $S_n \sim b(n, p)$, $E(\frac{S_n}{n}) = p$, $Var(\frac{S_n}{n}) = \frac{p(1-p)}{n}$. 由切比雪夫不等式有

$$P(|\frac{S_n}{n} - p| \geq \epsilon) \leq \frac{p(1-p)}{n\epsilon^2}.$$

也就是 $1 - \frac{p(1-p)}{n\epsilon^2} \leq P(|\frac{S_n}{n} - p| < \epsilon) \leq 1$.

大数定律

- (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为每次试验中 A 发生的概率, 则对任意的 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\frac{S_n}{n} - p| < \epsilon) = 1.$$

也就是说 $\frac{S_n}{n} \xrightarrow{P} p$.

- $S_n \sim b(n, p)$, $E(\frac{S_n}{n}) = p$, $Var(\frac{S_n}{n}) = \frac{p(1-p)}{n}$. 由切比雪夫不等式有

$$P(|\frac{S_n}{n} - p| \geq \epsilon) \leq \frac{p(1-p)}{n\epsilon^2}.$$

也就是 $1 - \frac{p(1-p)}{n\epsilon^2} \leq P(|\frac{S_n}{n} - p| < \epsilon) \leq 1$.

- 可以通过大量重复试验得到真实概率的近似值。

蒙特卡罗方法求积分一

- 设二维随机变量服从正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布, 则 X 与 Y 相互独立, 且均服从 $[0,1]$ 上的均匀分布,

蒙特卡罗方法求积分一

- 设二维随机变量服从正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布, 则 X 与 Y 相互独立, 且均服从 $[0,1]$ 上的均匀分布, 考虑 $[0,1]$ 上的函数 $f(x)$, 且 $0 \leq f(x) \leq 1$, 令 $A = \{Y \leq f(X)\}$,

蒙特卡罗方法求积分一

- 设二维随机变量服从正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布, 则 X 与 Y 相互独立, 且均服从 $[0,1]$ 上的均匀分布, 考虑 $[0,1]$ 上的函数 $f(x)$, 且 $0 \leq f(x) \leq 1$, 令 $A = \{Y \leq f(X)\}$, 则

$$P(A) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx.$$

- 设计伯努利试验: 每次任取 $(x, y) \in [0,1] \times [0,1]$, 记录 A 发生的次数。频率近似积分 $\int_0^1 f(x) dx$.

蒙特卡罗方法求积分一

- 设二维随机变量服从正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布, 则 X 与 Y 相互独立, 且均服从 $[0,1]$ 上的均匀分布, 考虑 $[0,1]$ 上的函数 $f(x)$, 且 $0 \leq f(x) \leq 1$, 令 $A = \{Y \leq f(X)\}$, 则

$$P(A) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx.$$

- 设计伯努利试验: 每次任取 $(x, y) \in [0,1] \times [0,1]$, 记录 A 发生的次数。频率近似积分 $\int_0^1 f(x) dx$.
- 对于一般区间 $[a, b]$ 上的函数 $g(x)$, 若 $c \leq g(x) \leq d$, 则令

$$f(y) = \frac{1}{d-c} [g(a + (b-a)y) - c]$$

$$\int_a^b g(x) dx = \int_0^1 g(a + (b-a)y) (b-a) dy = \frac{d-c}{b-a} \int_0^1 f(y) dy + (b-a)c.$$

大数定律的一般形式

- 一随机变量序列 $\{X_n\}$ 若满足性质：对于任意的 $\epsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k)\right| < \epsilon\right) = 1,$$

则称该随机变量序列 $\{X_n\}$ 服从大数定律。

大数定律的一般形式

- 一随机变量序列 $\{X_n\}$ 若满足性质：对于任意的 $\epsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k)\right| < \epsilon\right) = 1,$$

则称该随机变量序列 $\{X_n\}$ 服从大数定律。

- (切比雪夫大数定律) 若 $\{X_n\}$ 为两两互不相关的随机变量序列, 若每个 X_n 的方差存在, 且有共同上界, 即

$$\text{Var}(X_n) \leq c < \infty, n = 1, 2, \dots$$

则该序列服从大数定律。

大数定律的一般形式

- 一随机变量序列 $\{X_n\}$ 若满足性质：对于任意的 $\epsilon > 0$, 均有

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n E(X_k)\right| < \epsilon\right) = 1,$$

则称该随机变量序列 $\{X_n\}$ 服从大数定律。

- (切比雪夫大数定律) 若 $\{X_n\}$ 为两两互不相关的随机变量序列, 若每个 X_n 的方差存在, 且有共同上界, 即

$$\text{Var}(X_n) \leq c < \infty, n = 1, 2, \dots$$

则该序列服从大数定律。

- 伯努利大数定律是切比雪夫大数定律的特例。

切比雪夫大数定律的证明

•

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \leq \frac{c}{n}.$$

• 对于任意的 $\epsilon > 0$, 有切比雪夫不等式有,

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \epsilon\right) \geq 1 - \frac{c}{n\epsilon^2}.$$

- $\{X_n\}$ 是独立同分布随机变量, $E(X_n^4) < \infty$, 则对于任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i))^2 - \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i)| < \epsilon) = 1.$$

例子

- $\{X_n\}$ 是独立同分布随机变量, $E(X_n^4) < \infty$, 则对于任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i))^2 - \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i)| < \epsilon) = 1.$$

- 令 $Y_n = (X_n - E(X_n))^2$,

- $\{X_n\}$ 是独立同分布随机变量, $E(X_n^4) < \infty$, 则对于任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i))^2 - \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i)\right| < \epsilon\right) = 1.$$

- 令 $Y_n = (X_n - E(X_n))^2$, 则
 $\text{Var}(Y_n) = E\left(X_n - E(X_n)\right)^4 - (\text{Var}(X_n))^2 < \infty.$

- $\{X_n\}$ 是独立同分布随机变量, $E(X_n^4) < \infty$, 则对于任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i))^2 - \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i)| < \epsilon) = 1.$$

- 令 $Y_n = (X_n - E(X_n))^2$, 则
 $\text{Var}(Y_n) = E(X_n - E(X_n))^4 - (\text{Var}(X_n))^2 < \infty$. 满足切比雪夫大数定律的条件。

- $\{X_n\}$ 是独立同分布随机变量, $E(X_n^4) < \infty$, 则对于任意的 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\frac{1}{n} \sum_{i=1}^n (X_i - E(X_i))^2 - \frac{1}{n} \sum_{i=1}^n \text{Var}(X_i)| < \epsilon) = 1.$$

- 令 $Y_n = (X_n - E(X_n))^2$, 则
 $\text{Var}(Y_n) = E(X_n - E(X_n))^4 - (\text{Var}(X_n))^2 < \infty$. 满足切比雪夫大数定律的条件。
- $\frac{1}{n} \sum_{i=1}^n \text{Var}(X_i) = \text{Var}(X)$, 方差统计量的理论基础。

马尔可夫大数定律

- 对于随机变量序列 $\{X_n\}$, 若

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) \rightarrow 0, \quad n \rightarrow \infty,$$

则该随机变量序列满足大数定律。

马尔可夫大数定律

- 对于随机变量序列 $\{X_n\}$, 若

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) \rightarrow 0, \quad n \rightarrow \infty,$$

则该随机变量序列满足大数定律。

- 设 $\{X_n\}$ 为一同分布, 方差存在的随机变量序列, 且 X_n 仅与相邻的 X_{n-1} 和 X_{n+1} 相关, 而与其他的不相关, 则该序列服从大数定律。

马尔可夫大数定律

- 对于随机变量序列 $\{X_n\}$, 若

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) \rightarrow 0, \quad n \rightarrow \infty,$$

则该随机变量序列满足大数定律。

- 设 $\{X_n\}$ 为一同分布, 方差存在的随机变量序列, 且 X_n 仅与相邻的 X_{n-1} 和 X_{n+1} 相关, 而与其他的不相关, 则该序列服从大数定律。
-

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) = \frac{1}{n^2} \left[\sum_{k=1}^n \text{Var}(X_k) + 2 \sum_{i=1}^{n-1} \text{Cov}(X_i, X_{i+1}) \right] \rightarrow 0, \quad n \rightarrow \infty$$

马尔可夫大数定律

- 对于随机变量序列 $\{X_n\}$, 若

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) \rightarrow 0, \quad n \rightarrow \infty,$$

则该随机变量序列满足大数定律。

- 设 $\{X_n\}$ 为一同分布, 方差存在的随机变量序列, 且 X_n 仅与相邻的 X_{n-1} 和 X_{n+1} 相关, 而与其他的不相关, 则该序列服从大数定律。
-

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) = \frac{1}{n^2} \left[\sum_{k=1}^n \text{Var}(X_k) + 2 \sum_{i=1}^{n-1} \text{Cov}(X_i, X_{i+1}) \right] \rightarrow 0, \quad n \rightarrow \infty$$

- 跟相邻的任意有限 m 个相关, 也成立。

马尔可夫大数定律

- 对于随机变量序列 $\{X_n\}$, 若

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) \rightarrow 0, \quad n \rightarrow \infty,$$

则该随机变量序列满足大数定律。

- 设 $\{X_n\}$ 为一同分布, 方差存在的随机变量序列, 且 X_n 仅与相邻的 X_{n-1} 和 X_{n+1} 相关, 而与其他的无关, 则该序列服从大数定律。
-

$$\frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n X_k\right) = \frac{1}{n^2} \left[\sum_{k=1}^n \text{Var}(X_k) + 2 \sum_{i=1}^{n-1} \text{Cov}(X_i, X_{i+1}) \right] \rightarrow 0, \quad n \rightarrow \infty$$

- 跟相邻的任意有限 m 个相关, 也成立。可以更一般 (作业)。

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列，且 X_n 的数学期望存在，则该序列服从大数定律。

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列, 且 X_n 的数学期望存在, 则该序列服从大数定律。

•

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a = E(X_1), \quad n \rightarrow \infty.$$

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列, 且 X_n 的数学期望存在, 则该序列服从大数定律。

•

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a = E(X_1), \quad n \rightarrow \infty.$$

- X_n 的特征函数为 $\varphi(t) = \varphi(0) + \varphi'(0)t + o(t) = 1 + iat + o(t)$.

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列, 且 X_n 的数学期望存在, 则该序列服从大数定律。

•

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a = E(X_1), \quad n \rightarrow \infty.$$

- X_n 的特征函数为 $\varphi(t) = \varphi(0) + \varphi'(0)t + o(t) = 1 + iat + o(t)$.
- $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$ 的特征函数为

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列, 且 X_n 的数学期望存在, 则该序列服从大数定律。

-

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a = E(X_1), \quad n \rightarrow \infty.$$

- X_n 的特征函数为 $\varphi(t) = \varphi(0) + \varphi'(0)t + o(t) = 1 + iat + o(t)$.
- $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$ 的特征函数为

$$\varphi_{Y_n}(t) = [\varphi(\frac{t}{n})]^n = (1 + ia\frac{t}{n} + o(\frac{t}{n}))^n \rightarrow e^{iat}.$$

- e^{iat} 为常值 (随机变量) $X = a$ 的特征函数, 所以

$$Y_n \xrightarrow{L} a \Rightarrow Y_n \xrightarrow{P} a.$$

辛钦大数定律

- 若 $\{X_n\}$ 为独立同分布的随机变量序列, 且 X_n 的数学期望存在, 则该序列服从大数定律。

•

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a = E(X_1), \quad n \rightarrow \infty.$$

- X_n 的特征函数为 $\varphi(t) = \varphi(0) + \varphi'(0)t + o(t) = 1 + iat + o(t)$.
- $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$ 的特征函数为

$$\varphi_{Y_n}(t) = [\varphi(\frac{t}{n})]^n = (1 + ia\frac{t}{n} + o(\frac{t}{n}))^n \rightarrow e^{iat}.$$

- e^{iat} 为常值 (随机变量) $X = a$ 的特征函数, 所以

$$Y_n \xrightarrow{L} a \Rightarrow Y_n \xrightarrow{P} a.$$

- 注意: 这里并不要求方差存在!

一个例子：数学期望必须存在！

- 设随机变量 X_1, \dots, X_n 相互独立且服从同一柯西分布，其密度函数均为

$$p(x) = \frac{1}{\pi(1+x^2)},$$

考虑

$$Y = \frac{1}{n}(X_1 + \dots + X_n)$$

的密度函数。

一个例子：数学期望必须存在！

- 设随机变量 X_1, \dots, X_n 相互独立且服从同一柯西分布，其密度函数均为

$$p(x) = \frac{1}{\pi(1+x^2)},$$

考虑

$$Y = \frac{1}{n}(X_1 + \dots + X_n)$$

的密度函数。

- X_i 的特征函数为 $\varphi(t) = e^{-|t|}$,

一个例子：数学期望必须存在！

- 设随机变量 X_1, \dots, X_n 相互独立且服从同一柯西分布，其密度函数均为

$$p(x) = \frac{1}{\pi(1+x^2)},$$

考虑

$$Y = \frac{1}{n}(X_1 + \dots + X_n)$$

的密度函数。

- X_i 的特征函数为 $\varphi(t) = e^{-|t|}$,
- $X = X_1 + \dots + X_n$ 的特征函数为 $\varphi_X(t) = (e^{-|t|})^n = e^{-n|t|}$,

一个例子：数学期望必须存在！

- 设随机变量 X_1, \dots, X_n 相互独立且服从同一柯西分布，其密度函数均为

$$p(x) = \frac{1}{\pi(1+x^2)},$$

考虑

$$Y = \frac{1}{n}(X_1 + \dots + X_n)$$

的密度函数。

- X_i 的特征函数为 $\varphi(t) = e^{-|t|}$,
- $X = X_1 + \dots + X_n$ 的特征函数为 $\varphi_X(t) = (e^{-|t|})^n = e^{-n|t|}$,
- Y 的特征函数为 $\varphi_Y(t) = \varphi_X(\frac{t}{n}) = e^{-|t|}$,

一个例子：数学期望必须存在！

- 设随机变量 X_1, \dots, X_n 相互独立且服从同一柯西分布，其密度函数均为

$$p(x) = \frac{1}{\pi(1+x^2)},$$

考虑

$$Y = \frac{1}{n}(X_1 + \dots + X_n)$$

的密度函数。

- X_i 的特征函数为 $\varphi(t) = e^{-|t|}$,
- $X = X_1 + \dots + X_n$ 的特征函数为 $\varphi_X(t) = (e^{-|t|})^n = e^{-n|t|}$,
- Y 的特征函数为 $\varphi_Y(t) = \varphi_X(\frac{t}{n}) = e^{-|t|}$,
- 所以 Y 的密度函数为 $p(y) = \frac{1}{\pi(1+y^2)}$, $-\infty < y < \infty$.

蒙特卡罗方法求积分二

- 设 X 为 $[a, b]$ 上的均匀分布, 则 $Y = f(X)$ 的数学期望是

$$E(Y) = \int_a^b f(x) dx.$$

蒙特卡罗方法求积分二

- 设 X 为 $[a, b]$ 上的均匀分布, 则 $Y = f(X)$ 的数学期望是

$$E(Y) = \int_a^b f(x) dx.$$

- $X_i \sim U(a, b)$ 相互独立, 则 $f(X_i)$ 相互独立。

蒙特卡罗方法求积分二

- 设 X 为 $[a, b]$ 上的均匀分布, 则 $Y = f(X)$ 的数学期望是

$$E(Y) = \int_a^b f(x) dx.$$

- $X_i \sim U(a, b)$ 相互独立, 则 $f(X_i)$ 相互独立。

-

$$\frac{1}{n} \sum_{i=1}^n f(X_i) \rightarrow \int_a^b f(x) dx.$$

蒙特卡罗方法求积分二

- 设 X 为 $[a, b]$ 上的均匀分布, 则 $Y = f(X)$ 的数学期望是

$$E(Y) = \int_a^b f(x) dx.$$

- $X_i \sim U(a, b)$ 相互独立, 则 $f(X_i)$ 相互独立。

-

$$\frac{1}{n} \sum_{i=1}^n f(X_i) \rightarrow \int_a^b f(x) dx.$$

- 可以推广到多重积分。这种计算方法在二重以上的积分才比较有意义。

- X_n 是独立同分布的随机变量序列, $\frac{1}{n} \sum_{i=1}^n X_n^k \rightarrow ?$, $k \geq 1$

样本矩：抢先版

- X_n 是独立同分布的随机变量序列, $\frac{1}{n} \sum_{i=1}^n X_n^k \rightarrow ?$, $k \geq 1$
- 只要 $E(X_n^k)$ 存在, 有辛欣大数定律, 它收敛到 $E(X^k)$.

样本矩：抢先版

- X_n 是独立同分布的随机变量序列, $\frac{1}{n} \sum_{i=1}^n X_n^k \rightarrow ?$, $k \geq 1$
- 只要 $E(X_n^k)$ 存在, 有辛欣大数定律, 它收敛到 $E(X^k)$.
- $E(X^3)$ 存在, $f(x_1, x_2, x_3)$ 是连续函数, 则

$$f\left(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n} \sum_{i=1}^n X_i^2, \frac{1}{n} \sum_{i=1}^n X_i^3\right) \rightarrow f(E(X), E(X^2), E(X^3)).$$

- X_n 是独立同分布的随机变量序列, $\frac{1}{n} \sum_{i=1}^n X_n^k \rightarrow ?$, $k \geq 1$
- 只要 $E(X_n^k)$ 存在, 有辛欣大数定律, 它收敛到 $E(X^k)$.
- $E(X^3)$ 存在, $f(x_1, x_2, x_3)$ 是连续函数, 则

$$f\left(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n} \sum_{i=1}^n X_i^2, \frac{1}{n} \sum_{i=1}^n X_i^3\right) \rightarrow f(E(X), E(X^2), E(X^3)).$$

- 这是后面学习的矩法构造统计估计量的基础。

强大数定律

- (博雷尔强大数定律) 设 X_n 为独立同分布随机变量序列, 且

$$P(X_n = 1) = p, \quad P(X_n = 0) = 1 - p,$$

则

$$\frac{1}{n} \sum_{k=1}^n X_k \rightarrow p, \quad a.s.$$

- (柯尔莫哥洛夫强大数定律) 设 X_n 为独立同分布随机变量序列, 且 $E(|X_n|) < \infty$, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \rightarrow E(X_1), \quad a.s.$$

强大数定律

- (博雷尔强大数定律) 设 X_n 为独立同分布随机变量序列, 且

$$P(X_n = 1) = p, \quad P(X_n = 0) = 1 - p,$$

则

$$\frac{1}{n} \sum_{k=1}^n X_k \rightarrow p, \quad a.s.$$

- (柯尔莫哥洛夫强大数定律) 设 X_n 为独立同分布随机变量序列, 且 $E(|X_n|) < \infty$, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \rightarrow E(X_1), \quad a.s.$$

本页内容不做考试要求.

中心极限定理

- 中心极限定理考察随机变量和 $Y_n = X_1 + \cdots + X_n$ 的分布。

中心极限定理

- 中心极限定理考察随机变量和 $Y_n = X_1 + \cdots + X_n$ 的分布。
- 标准化: $Y_n^* = \frac{Y_n - E(Y_n)}{\sqrt{\text{Var}(Y_n)}}$.

中心极限定理

- 中心极限定理考察随机变量和 $Y_n = X_1 + \cdots + X_n$ 的分布。
- 标准化: $Y_n^* = \frac{Y_n - E(Y_n)}{\sqrt{\text{Var}(Y_n)}}$.
- 林德伯格-莱维 (Lindeberg-Levy) 中心极限定理: 设 $\{X_n\}$ 是独立同分布的随机变量序列, 且 $E(X_n) = \mu$, $\text{Var}(X_n) = \sigma^2$ 均存在, 若记

$$Y_n^* = \frac{X_1 + \cdots + X_n - n\mu}{\sigma\sqrt{n}},$$

则对任意实数 y , 有,

$$\lim_{n \rightarrow \infty} P(Y_n^* \leq y) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

Lindeberg-Levy 中心极限定理的证明

- 因为 $E(X_n - \mu) = 0$, $Var(X_n - \mu) = \sigma^2$, 所以随机变量 $X_n - \mu$ 的特征函数可表示为

$$\varphi(t) = \varphi(0) + \varphi'(0)t + \frac{1}{2!}\varphi''(0)t^2 + o(t^2) = 1 - \frac{\sigma^2 t^2}{2} + o(t^2).$$

Lindeberg-Levy 中心极限定理的证明

- 因为 $E(X_n - \mu) = 0$, $Var(X_n - \mu) = \sigma^2$, 所以随机变量 $X_n - \mu$ 的特征函数可表示为

$$\varphi(t) = \varphi(0) + \varphi'(0)t + \frac{1}{2!}\varphi''(0)t^2 + o(t^2) = 1 - \frac{\sigma^2 t^2}{2} + o(t^2).$$

- Y_n^* 的特征函数为

$$\varphi_{Y_n^*}(t) = (\varphi(\frac{t}{\sigma\sqrt{n}}))^n = [1 - \frac{t^2}{2n} + o(\frac{t^2}{n})]^n \rightarrow e^{-\frac{t^2}{2}}.$$

- $e^{-\frac{t^2}{2}}$ 为标准正态分布的特征函数, 所以 Y_n^* 按分布收敛到一个标准正态分布随机变量。

例子

- X_n 是独立同分布的随机变量序列, $a = E(X_n^2)$, $b = E(X_n^4)$,

$$\frac{\sum_{i=1}^n X_n^2}{\sqrt{n}} \sim ?, \quad n \gg 1,$$

例子

- X_n 是独立同分布的随机变量序列, $a = E(X_n^2)$, $b = E(X_n^4)$,

$$\frac{\sum_{i=1}^n X_n^2}{\sqrt{n}} \sim ?, \quad n \gg 1,$$

- $\text{Var}(X_n^2) = b - a^2$,

例子

- X_n 是独立同分布的随机变量序列, $a = E(X_n^2)$, $b = E(X_n^4)$,

$$\frac{\sum_{i=1}^n X_n^2}{\sqrt{n}} \sim ?, \quad n \gg 1,$$

- $\text{Var}(X_n^2) = b - a^2$, 所以

$$\frac{\sum_{i=1}^n (X_n^2 - a)}{\sqrt{b - a^2} \sqrt{n}} \rightarrow N(0, 1).$$

例子

- X_n 是独立同分布的随机变量序列, $a = E(X_n^2)$, $b = E(X_n^4)$,

$$\frac{\sum_{i=1}^n X_n^2}{\sqrt{n}} \sim ?, \quad n \gg 1,$$

- $\text{Var}(X_n^2) = b - a^2$, 所以

$$\frac{\sum_{i=1}^n (X_n^2 - a)}{\sqrt{b - a^2} \sqrt{n}} \rightarrow N(0, 1).$$

$$\frac{\sum_{i=1}^n X_n^2}{\sqrt{n}} \sim N(a\sqrt{n}, (b - a^2)).$$

独立不同分布下的中心极限定理

- 林德伯格中心极限定理：设 $\{X_n\}$ 为一个相互独立的随机变量序列，且它们具有有限的数学期望和方差：

$$E(X_n) = \mu_n, \quad \text{Var}(X_n) = \sigma_n^2, \quad n = 1, 2, \dots$$

令 $B_n = \sqrt{\sigma_1^2 + \dots + \sigma_n^2}$, 若对于任意的 $\tau > 0$, 有

$$\lim_{n \rightarrow \infty} \frac{1}{\tau^2 B_n^2} \sum_{k=1}^n \int_{|x - \mu_i| > \tau B_n} (x - \mu_i)^2 p_i(x) dx = 0,$$

则对于任意 $x \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$$

例子：林德伯格条件的验证

- 设 X_n 为独立同分布的随机变量序列，且数学期望和方差均存在，则

$$\frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-\mu_k| > \tau B_n} (x-\mu_k)^2 p_k(x) dx = \frac{n}{n\sigma^2} \int_{|x-\mu| > \tau\sqrt{n}\sigma} (x-\mu)^2 p(x) dx.$$

例子：林德伯格条件的验证

- 设 X_n 为独立同分布的随机变量序列，且数学期望和方差均存在，则

$$\frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-\mu_k|>\tau B_n} (x-\mu_k)^2 p_k(x) dx = \frac{n}{n\sigma^2} \int_{|x-\mu|>\tau\sqrt{n}\sigma} (x-\mu)^2 p(x) dx.$$

- 因为方差有限，即

$$\text{Var}(X_k) = \int_{-\infty}^{\infty} (x-\mu)^2 p(x) dx < \infty,$$

- 所以有

$$\lim_{n \rightarrow \infty} \int_{|x-\mu|>\tau\sigma\sqrt{n}} |x-\mu|^2 p(x) dx = 0.$$

独立不同分布下的中心极限定理

- (李雅普诺夫中心极限定理) 设 $\{X_n\}$ 为独立随机变量序列, 若存在 $\delta > 0$, 满足

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E(|X_k - \mu_k|^{2+\delta}) = 0,$$

则对于任意 $x \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

独立不同分布下的中心极限定理

- (李雅普诺夫中心极限定理) 设 $\{X_n\}$ 为独立随机变量序列, 若存在 $\delta > 0$, 满足

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E(|X_k - \mu_k|^{2+\delta}) = 0,$$

则对于任意 $x \in \mathbb{R}$, 有

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

- 满足 Lindeberg 条件:

$$\begin{aligned} E(|X_k - \mu_k|^{2+\delta}) &= \int_{-\infty}^{\infty} |x - \mu_k|^{2+\delta} p_k(x) dx \\ &\geq \int_{\{x: |x - \mu_k| \geq \tau B_n\}} |x - \mu_k|^{2+\delta} p_k(x) dx \\ &\geq \tau^\delta B_n^\delta \int_{\{x: |x - \mu_k| \geq \tau B_n\}} |x - \mu_k|^2 p_k(x) dx. \end{aligned}$$

中心极限定理的应用

- 误差分析：在计算机中，所有实数 x 都是用由一定位数的小数 x' 来近似表示。这个近似过程产生误差 $\epsilon = x - x'$.

中心极限定理的应用

- 误差分析：在计算机中，所有实数 x 都是用由一定位数的小数 x' 来近似表示。这个近似过程产生误差 $\epsilon = x - x'$. 一般假设

$$\epsilon \sim U(-0.5 \times 10^{-k}, 0.5 \times 10^{-k}).$$

中心极限定理的应用

- 误差分析：在计算机中，所有实数 x 都是用由一定位数的小数 x' 来近似表示。这个近似过程产生误差 $\epsilon = x - x'$ 。一般假设

$$\epsilon \sim U(-0.5 \times 10^{-k}, 0.5 \times 10^{-k}).$$

- n 个实数 x_i 的和 S ，及其近似 S' ，则

$$S - S' = \sum_{i=1}^n x_i - x'_i = \sum_{i=1}^n \epsilon_i.$$

中心极限定理的应用

- 误差分析：在计算机中，所有实数 x 都是用由一定位数的小数 x' 来近似表示。这个近似过程产生误差 $\epsilon = x - x'$ 。一般假设

$$\epsilon \sim U(-0.5 \times 10^{-k}, 0.5 \times 10^{-k}).$$

- n 个实数 x_i 的和 S ，及其近似 S' ，则

$$S - S' = \sum_{i=1}^n x_i - x'_i = \sum_{i=1}^n \epsilon_i.$$

- 当 n 足够大时，近似地有 $\frac{\sum_{i=1}^n \epsilon_i}{\sqrt{n \frac{10^{-2k}}{12}}} \sim N(0, 1)$ 。则

$$P(|\sum_{i=1}^n \epsilon_i| \leq z) \approx 2\Phi(\frac{z\sqrt{12}}{\sqrt{n10^{-2k}}}) - 1.$$

中心极限定理的应用

- 二项分布的正态近似——棣莫弗-拉普拉斯中心极限定理：设 n 重伯努利试验中，事件 A 在每次试验中出现的概率为 p ($0 < p < 1$)，记 S_n 为 n 次试验中事件 A 出现的次数，则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt.$$

中心极限定理的应用

- 二项分布的正态近似——棣莫弗-拉普拉斯中心极限定理：设 n 重伯努利试验中，事件 A 在每次试验中出现的概率为 p ($0 < p < 1$)，记 S_n 为 n 次试验中事件 A 出现的次数，则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt.$$

- p 比较小时，用泊松分布近似比较合理。

中心极限定理的应用

- 二项分布的正态近似——棣莫弗-拉普拉斯中心极限定理：设 n 重伯努利试验中，事件 A 在每次试验中出现的概率为 p ($0 < p < 1$)，记 S_n 为 n 次试验中事件 A 出现的次数，则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{2\pi} \int_{-\infty}^y e^{-t^2/2} dt.$$

- p 比较小时，用泊松分布近似比较合理。 $np > 5$ 且 $n(1-p) > 5$ 时用正态分布近似比较合理。

中心极限定理的应用

- 二项分布的正态近似——棣莫弗-拉普拉斯中心极限定理：设 n 重伯努利试验中，事件 A 在每次试验中出现的概率为 p ($0 < p < 1$)，记 S_n 为 n 次试验中事件 A 出现的次数，则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{2\pi} \int_{-\infty}^y e^{-t^2/2} dt.$$

- p 比较小时，用泊松分布近似比较合理。 $np > 5$ 且 $n(1-p) > 5$ 时用正态分布近似比较合理。
- 修正近似：若 $a < b$ 均为正整数，则

$$P(a \leq S_n \leq b) = P(a - 0.5 \leq S_n \leq b + 0.5).$$

中心极限定理的应用

- 二项分布的正态近似——棣莫弗-拉普拉斯中心极限定理：设 n 重伯努利试验中，事件 A 在每次试验中出现的概率为 p ($0 < p < 1$)，记 S_n 为 n 次试验中事件 A 出现的次数，则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{2\pi} \int_{-\infty}^y e^{-t^2/2} dt.$$

- p 比较小时，用泊松分布近似比较合理。 $np > 5$ 且 $n(1-p) > 5$ 时用正态分布近似比较合理。
- 修正近似：若 $a < b$ 均为正整数，则

$$P(a \leq S_n \leq b) = P(a - 0.5 \leq S_n \leq b + 0.5).$$

当 n 相对比较小时，一般更好的近似为

$$P(a \leq S_n \leq b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{np(1-p)}}\right).$$

二项分布的正态近似

- $P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) \approx \Phi(y) = \beta.$

二项分布的正态近似

- $P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) \approx \Phi(y) = \beta.$
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

二项分布的正态近似

- $P(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y) \approx \Phi(y) = \beta$.
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

$$P(Y_n \geq 85) \approx 1 - \Phi\left(\frac{85 - 0.5 - 90}{3}\right) = \Phi(5.5/3) \approx 0.9664.$$

二项分布的正态近似

- $P(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y) \approx \Phi(y) = \beta$.
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

$$P(Y_n \geq 85) \approx 1 - \Phi\left(\frac{85 - 0.5 - 90}{3}\right) = \Phi(5.5/3) \approx 0.9664.$$

- 给定 n, β , 求 y : 某工厂有 200 台机器, 在一个小时内, 每台机器有 70% 的时间在工作, 工作时消耗 15KW 电能, 问要多少电能才能以 95% 的可能性保证工厂正常工作呢?

二项分布的正态近似

- $P(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y) \approx \Phi(y) = \beta$.
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

$$P(Y_n \geq 85) \approx 1 - \Phi(\frac{85 - 0.5 - 90}{3}) = \Phi(5.5/3) \approx 0.9664.$$

- 给定 n, β , 求 y : 某工厂有 200 台机器, 在一个小时内, 每台机器有 70% 的时间在工作, 工作时消耗 15KW 电能, 问要多少电能才能以 95% 的可能性保证工厂正常工作呢? Y 为工作的机器数,
 $Y \sim b(200, 0.7)$, $E(Y) = 140$, $Var(Y) = 42$.

二项分布的正态近似

- $P(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y) \approx \Phi(y) = \beta$.
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

$$P(Y_n \geq 85) \approx 1 - \Phi(\frac{85 - 0.5 - 90}{3}) = \Phi(5.5/3) \approx 0.9664.$$

- 给定 n, β , 求 y : 某工厂有 200 台机器, 在一个小时内, 每台机器有 70% 的时间在工作, 工作时消耗 15KW 电能, 问要多少电能才能以 95% 的可能性保证工厂正常工作呢? Y 为工作的机器数, $Y \sim b(200, 0.7)$, $E(Y) = 140$, $Var(Y) = 42$. 则要求

$$P(15Y_n \leq y) \approx \Phi(\frac{y/15 + 0.5 - 140}{\sqrt{42}}) \geq 0.95.$$

二项分布的正态近似

- $P(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y) \approx \Phi(y) = \beta$.
- 给定 n, y , 求 β : 一个复杂系统由 100 个相互独立的部件组成, 每个部件正常工作的概率为 0.9. 系统要正常工作, 至少需要 85 个部件正常工作, 那系统正常工作的概率大约是?

$$P(Y_n \geq 85) \approx 1 - \Phi(\frac{85 - 0.5 - 90}{3}) = \Phi(5.5/3) \approx 0.9664.$$

- 给定 n, β , 求 y : 某工厂有 200 台机器, 在一个小时内, 每台机器有 70% 的时间在工作, 工作时消耗 15KW 电能, 问要多少电能才能以 95% 的可能性保证工厂正常工作呢? Y 为工作的机器数, $Y \sim b(200, 0.7)$, $E(Y) = 140$, $Var(Y) = 42$. 则要求

$$P(15Y_n \leq y) \approx \Phi(\frac{y/15 + 0.5 - 140}{\sqrt{42}}) \geq 0.95.$$

$$\frac{y/15 + 0.5 - 140}{\sqrt{42}} \geq 1.645, \quad \Rightarrow y \geq 2252.$$

二项分布的正态近似

- 给定 y, β , 求 n : 先要调查中央电视台新闻联播在清华大学的收视率 p , 调查人员准备将所有受访对象中观看该节目的人员频率 \hat{p} 来估计 p , 现在要以 90% 的把握认为 \hat{p} 和真实的 p 的差异不超过 5%。需要访问多少人?

二项分布的正态近似

- 给定 y, β , 求 n : 先要调查中央电视台新闻联播在清华大学的收视率 p , 调查人员准备将所有受访对象中观看该节目的人员频率 \hat{p} 来估计 p , 现在要以 90% 的把握认为 \hat{p} 和真实的 p 的差异不超过 5%。需要访问多少人?
- Y 为访问对象中收看新闻联播的人数, 则 $Y \sim b(n, p)$.

二项分布的正态近似

- 给定 y, β , 求 n : 先要调查中央电视台新闻联播在清华大学的收视率 p , 调查人员准备将所有受访对象中观看该节目的人员频率 \hat{p} 来估计 p , 现在要以 90% 的把握认为 \hat{p} 和真实的 p 的差异不超过 5%。需要访问多少人?
- Y 为访问对象中收看新闻联播的人数, 则 $Y \sim b(n, p)$. 则要求为

$$P\left(\left|\frac{Y}{n} - p\right| \leq 0.05\right) \geq 0.9,$$

二项分布的正态近似

- 给定 y, β , 求 n : 先要调查中央电视台新闻联播在清华大学的收视率 p , 调查人员准备将所有受访对象中观看该节目的人员频率 \hat{p} 来估计 p , 现在要以 90% 的把握认为 \hat{p} 和真实的 p 的差异不超过 5%。需要访问多少人?
- Y 为访问对象中收看新闻联播的人数, 则 $Y \sim b(n, p)$. 则要求为

$$P(|\frac{Y}{n} - p| \leq 0.05) \geq 0.9,$$

$$\begin{aligned} P(|\frac{Y}{n} - p| \leq 0.05) &= P(|\frac{(Y - np)}{\sqrt{np(1-p)}}| \leq \frac{0.05n}{\sqrt{np(1-p)}}) \\ &\approx 2\Phi(0.05\sqrt{\frac{n}{p(1-p)}}) - 1 \geq 0.95 \Rightarrow 0.05\sqrt{\frac{n}{p(1-p)}} \geq 1.645. \end{aligned}$$

二项分布的正态近似

- 给定 y, β , 求 n : 先要调查中央电视台新闻联播在清华大学的收视率 p , 调查人员准备将所有受访对象中观看该节目的人员频率 \hat{p} 来估计 p , 现在要以 90% 的把握认为 \hat{p} 和真实的 p 的差异不超过 5%。需要访问多少人?
- Y 为访问对象中收看新闻联播的人数, 则 $Y \sim b(n, p)$. 则要求为

$$P(|\frac{Y}{n} - p| \leq 0.05) \geq 0.9,$$

$$\begin{aligned} P(|\frac{Y}{n} - p| \leq 0.05) &= P(|\frac{(Y - np)}{\sqrt{np(1-p)}}| \leq \frac{0.05n}{\sqrt{np(1-p)}}) \\ &\approx 2\Phi(0.05\sqrt{\frac{n}{p(1-p)}}) - 1 \geq 0.95 \Rightarrow 0.05\sqrt{\frac{n}{p(1-p)}} \geq 1.645. \end{aligned}$$

$$n \geq p(1-p) \frac{1.645^2}{0.05^2}, \Rightarrow n \geq 0.25 \times 1082.41 \approx 271.$$

中心极限定理的逼近速度

- (Berry-Esseen 定理) 考虑独立同分布随机变量序列 $\{X_n\}$, 假设 $E(X_n) = 0$, $Var(X_n) = \sigma^2 < \infty$, 其 $E(|X_1|^3) < \infty$. 令

$$S_n = \frac{X_1 + \cdots + X_n}{\sigma\sqrt{n}},$$

其分布函数为 $F_n(x)$, 则有

$$\sup_x |F_n(x) - \Phi(x)| \leq C \frac{E|X_1|^3}{\sigma^3\sqrt{n}},$$

而 $\frac{1}{\sqrt{2\pi}} \leq C \leq 0.8$.

中心极限定的逼近速度

- Berry-Esseen 定理的结论一般情况下不能被加强：考虑独立同分布随机变量序列 $\{X_n\}$,

$$P(X_n = 1) = 0.5, \quad P(X_n = -1) = 0.5.$$

中心极限定的逼近速度

- Berry-Esseen 定理的结论一般情况下不能被加强：考虑独立同分布随机变量序列 $\{X_n\}$,

$$P(X_n = 1) = 0.5, \quad P(X_n = -1) = 0.5.$$

则对于任意 n ,

$$2P\left(\sum_{k=1}^{2n} X_k < 0\right) + P\left(\sum_{k=1}^{2n} X_k = 0\right) = 1.$$

中心极限定的逼近速度

- Berry-Esseen 定理的结论一般情况下不能被加强：考虑独立同分布随机变量序列 $\{X_n\}$,

$$P(X_n = 1) = 0.5, \quad P(X_n = -1) = 0.5.$$

则对于任意 n ,

$$2P\left(\sum_{k=1}^{2n} X_k < 0\right) + P\left(\sum_{k=1}^{2n} X_k = 0\right) = 1.$$

所以

$$\left|P\left(\sum_{k=1}^{2n} X_k < 0\right) - 0.5\right| = \frac{1}{2}P\left(\sum_{k=1}^{2n} X_k = 0\right) = \frac{1}{2}C_{2n}^n 2^{-2n} \sim \frac{1}{\sqrt{2\pi 2n}}.$$

中心极限定的逼近速度

- Berry-Esseen 定理的结论一般情况下不能被加强：考虑独立同分布随机变量序列 $\{X_n\}$,

$$P(X_n = 1) = 0.5, \quad P(X_n = -1) = 0.5.$$

则对于任意 n ,

$$2P\left(\sum_{k=1}^{2n} X_k < 0\right) + P\left(\sum_{k=1}^{2n} X_k = 0\right) = 1.$$

所以

$$\left|P\left(\sum_{k=1}^{2n} X_k < 0\right) - 0.5\right| = \frac{1}{2}P\left(\sum_{k=1}^{2n} X_k = 0\right) = \frac{1}{2}C_{2n}^n 2^{-2n} \sim \frac{1}{\sqrt{2\pi 2n}}.$$

Stirling 公式: $n! \sim \sqrt{2\pi n}e^{-n}n^n$.

中心极限定的逼近速度

- Berry-Esseen 定理的结论一般情况下不能被加强：考虑独立同分布随机变量序列 $\{X_n\}$,

$$P(X_n = 1) = 0.5, \quad P(X_n = -1) = 0.5.$$

则对于任意 n ,

$$2P\left(\sum_{k=1}^{2n} X_k < 0\right) + P\left(\sum_{k=1}^{2n} X_k = 0\right) = 1.$$

所以

$$\left|P\left(\sum_{k=1}^{2n} X_k < 0\right) - 0.5\right| = \frac{1}{2}P\left(\sum_{k=1}^{2n} X_k = 0\right) = \frac{1}{2}C_{2n}^m 2^{-2n} \sim \frac{1}{\sqrt{2\pi 2n}}.$$

$$\text{Stirling 公式: } n! \sim \sqrt{2\pi n} e^{-n} n^n. C_{2n}^m = \frac{(2n)!}{(n!)^2} \sim 2^{2n} \frac{1}{\sqrt{\pi n}}.$$