

概率论与数理统计 (10)

清华大学

2020 年春季学期

最大似然估计

- 设总体的概率函数为 $p(x; \theta)$, θ 是一个未知参数或者未知参数组成的参数向量。 x_1, \dots, x_n 是来自该总体的样本, 将样本的联合密度函数看作 θ 的函数, 则

$$L(\theta) = L(\theta; x_1, \dots, x_n) := \prod_{i=1}^n p(x_i; \theta),$$

称为样本的似然函数。如果某统计量 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ 满足

$$L(\hat{\theta}) = \max_{\theta} L(\theta)$$

则称 $\hat{\theta}$ 是 θ 的最大似然估计, 简记为 MLE (maximum likelihood estimator).

最大似然估计

- 由于 $\ln x$ 是 x 的单调函数, $\ln L(\theta)$ 到达最大值和 $L(\theta)$ 到达最大值是等价的。

最大似然估计

- 由于 $\ln x$ 是 x 的单调函数, $\ln L(\theta)$ 到达最大值和 $L(\theta)$ 到达最大值是等价的。
- 当 $\ln L(\theta)$ 是可微函数时, 一般通过求导的方式寻找 $\hat{\theta}$.

最大似然估计

- 由于 $\ln x$ 是 x 的单调函数, $\ln L(\theta)$ 到达最大值和 $L(\theta)$ 到达最大值是等价的。
- 当 $\ln L(\theta)$ 是可微函数时, 一般通过求导的方式寻找 $\hat{\theta}$.
- 总体是二点分布 $b(1, p)$, x_1, \dots, x_n 为其样本, 则

$$L(p; x_1, \dots, x_n) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}.$$

最大似然估计

- 由于 $\ln x$ 是 x 的单调函数, $\ln L(\theta)$ 到达最大值和 $L(\theta)$ 到达最大值是等价的。
- 当 $\ln L(\theta)$ 是可微函数时, 一般通过求导的方式寻找 $\hat{\theta}$ 。
- 总体是二点分布 $b(1, p)$, x_1, \dots, x_n 为其样本, 则

$$L(p; x_1, \dots, x_n) = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}.$$

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p).$$

$$\partial_p \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} + \frac{n - \sum_{i=1}^n x_i}{1-p} = 0.$$

$$p = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}. \quad \partial_p^2 \ln L(p) = -\frac{n^2}{\bar{x}} - \frac{n^2}{1-\bar{x}} < 0$$

最大似然估计

- 总体是指数分布 $Exp(\lambda)$: $p(x, \lambda) = \lambda e^{-\lambda x}$.

最大似然估计

- 总体是指数分布 $Exp(\lambda)$: $p(x, \lambda) = \lambda e^{-\lambda x}$.
- 似然函数为

$$L(\lambda) = \ln \prod_{i=1}^n \lambda e^{-\lambda x_i} = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

最大似然估计

- 总体是指数分布 $Exp(\lambda)$: $p(x, \lambda) = \lambda e^{-\lambda x}$.
- 似然函数为

$$L(\lambda) = \ln \prod_{i=1}^n \lambda e^{-\lambda x_i} = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

$$\frac{n}{\lambda} - \sum_{i=1}^n x_i = 0.$$

最大似然估计

- 总体是指数分布 $Exp(\lambda)$: $p(x, \lambda) = \lambda e^{-\lambda x}$.
- 似然函数为

$$L(\lambda) = \ln \prod_{i=1}^n \lambda e^{-\lambda x_i} = n \ln \lambda - \lambda \sum_{i=1}^n x_i.$$

$$\frac{n}{\lambda} - \sum_{i=1}^n x_i = 0.$$

$$\hat{\lambda} = \frac{1}{\frac{1}{n} \sum_{i=1}^n x_i} = \frac{1}{\bar{x}}.$$

$$\partial_{\lambda}^2 L(\lambda) = -\frac{n}{\lambda^2} < 0.$$

最大似然估计

- 总体是正态分布 $N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$:

最大似然估计

- 总体是正态分布 $N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$:

$$\begin{aligned}\ln L(\mu, \sigma^2) &= \ln\left(\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}\right)\right) \\ &= -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} - \frac{n \ln \sigma^2}{2} - \frac{n \ln 2\pi}{2}.\end{aligned}$$

最大似然估计

- 总体是正态分布 $N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$:

$$\begin{aligned}\ln L(\mu, \sigma^2) &= \ln\left(\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}\right)\right) \\ &= -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} - \frac{n \ln \sigma^2}{2} - \frac{n \ln 2\pi}{2}.\end{aligned}$$

$$\begin{cases} \partial_{\mu} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} = 0, \\ \partial_{\sigma^2} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} - \frac{n}{2\sigma^2} = 0. \end{cases}$$

最大似然估计

- 总体是正态分布 $N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$:

$$\begin{aligned}\ln L(\mu, \sigma^2) &= \ln\left(\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}\right)\right) \\ &= -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} - \frac{n \ln \sigma^2}{2} - \frac{n \ln 2\pi}{2}.\end{aligned}$$

$$\begin{cases} \partial_{\mu} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} = 0, \\ \partial_{\sigma^2} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} - \frac{n}{2\sigma^2} = 0. \end{cases}$$

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2.$$

最大似然估计

- 总体是正态分布 $N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$:

$$\begin{aligned}\ln L(\mu, \sigma^2) &= \ln\left(\prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}\right)\right) \\ &= -\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} - \frac{n \ln \sigma^2}{2} - \frac{n \ln 2\pi}{2}.\end{aligned}$$

$$\begin{cases} \partial_{\mu} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)}{\sigma^2} = 0, \\ \partial_{\sigma^2} \ln L(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^4} - \frac{n}{2\sigma^2} = 0. \end{cases}$$

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = s_n^2.$$

- 最大似然估计不一定是无偏估计。

最大似然估计

- 设总体的概率密度函数 $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}$, $x > c$, $c > 0$ 为已知, $\theta > 1$ 为未知参数, x_1, \dots, x_n 为样本, 求 θ 的最大似然估计。

最大似然估计

- 设总体的概率密度函数 $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}$, $x > c$, $c > 0$ 为已知, $\theta > 1$ 为未知参数, x_1, \dots, x_n 为样本, 求 θ 的最大似然估计。
- 对数似然函数为

$$L(\theta) = \ln \theta^n c^{n\theta} \left(\prod_{i=1}^n x_i \right)^{-(\theta+1)} = n \ln \theta + n\theta \ln c - (\theta+1) \left(\sum_{i=1}^n \ln x_i \right).$$

最大似然估计

- 设总体的概率密度函数 $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}$, $x > c$, $c > 0$ 为已知, $\theta > 1$ 为未知参数, x_1, \dots, x_n 为样本, 求 θ 的最大似然估计。
- 对数似然函数为

$$L(\theta) = \ln \theta^n c^{n\theta} \left(\prod_{i=1}^n x_i \right)^{-(\theta+1)} = n \ln \theta + n\theta \ln c - (\theta+1) \left(\sum_{i=1}^n \ln x_i \right).$$

$$\partial_\theta L(\theta) = \frac{n}{\theta} + n \ln c - \sum_{i=1}^n \ln x_i = 0$$

最大似然估计

- 设总体的概率密度函数 $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}$, $x > c$, $c > 0$ 为已知, $\theta > 1$ 为未知参数, x_1, \dots, x_n 为样本, 求 θ 的最大似然估计。
- 对数似然函数为

$$L(\theta) = \ln \theta^n c^{n\theta} \left(\prod_{i=1}^n x_i \right)^{-(\theta+1)} = n \ln \theta + n\theta \ln c - (\theta+1) \left(\sum_{i=1}^n \ln x_i \right).$$

$$\partial_\theta L(\theta) = \frac{n}{\theta} + n \ln c - \sum_{i=1}^n \ln x_i = 0$$

$$\hat{\theta} = \left(\frac{1}{n} \sum_{i=1}^n \ln x_i - \ln c \right)^{-1}.$$

最大似然估计

- 设总体的概率密度函数 $p(x; \theta) = \theta c^\theta x^{-(\theta+1)}$, $x > c$, $c > 0$ 为已知, $\theta > 1$ 为未知参数, x_1, \dots, x_n 为样本, 求 θ 的最大似然估计。
- 对数似然函数为

$$L(\theta) = \ln \theta^n c^{n\theta} \left(\prod_{i=1}^n x_i \right)^{-(\theta+1)} = n \ln \theta + n\theta \ln c - (\theta+1) \left(\sum_{i=1}^n \ln x_i \right).$$

$$\partial_\theta L(\theta) = \frac{n}{\theta} + n \ln c - \sum_{i=1}^n \ln x_i = 0$$

$$\hat{\theta} = \left(\frac{1}{n} \sum_{i=1}^n \ln x_i - \ln c \right)^{-1}.$$

$$\partial_\theta^2 L(\theta) = -\frac{n}{\theta^2} < 0.$$

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}.$$

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}.$$

- 并不是处处可导的函数。

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}.$$

- 并不是处处可导的函数。
- $\theta > 0$ 时, $\frac{1}{\theta^n}$ 是关于 θ 单调递减, 所以 θ 越小, 似然函数越大。

最大似然估计

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}.$$

- 并不是处处可导的函数。
- $\theta > 0$ 时, $\frac{1}{\theta^n}$ 是关于 θ 单调递减, 所以 θ 越小, 似然函数越大。
- 示性函数 $I_{\{x_{(n)} \leq \theta\}}$: 如果 θ 小于 $x_{(n)}$, 则等于 0, 所以 θ 不能小于 $x_{(n)}$ 。

最大似然估计

- 总体是均匀分布 $U(0, \theta)$, 似然函数为

$$L(\theta) = \frac{1}{\theta^n} \prod_{i=1}^n I_{\{0 < x_i \leq \theta\}} = \frac{1}{\theta^n} I_{\{x_{(n)} \leq \theta\}}.$$

- 并不是处处可导的函数。
- $\theta > 0$ 时, $\frac{1}{\theta^n}$ 是关于 θ 单调递减, 所以 θ 越小, 似然函数越大。
- 示性函数 $I_{\{x_{(n)} \leq \theta\}}$: 如果 θ 小于 $x_{(n)}$, 则等于 0, 所以 θ 不能小于 $x_{(n)}$ 。
- 所以最大似然估计为 $\hat{\theta} = x_{(n)}$ 。

最大似然估计

- 总体为 $U(\theta, (k+1)\theta)$, $\theta > 0$, 求 θ 的最大似然估计。

最大似然估计

- 总体为 $U(\theta, (k+1)\theta)$, $\theta > 0$, 求 θ 的最大似然估计。
- 似然函数 $L(\theta) = \frac{1}{(k\theta)^n} I_{\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta}$.
- 让似然函数大, θ 应该尽可能的小。由 $\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta$, 有 $\frac{x_{(n)}}{k+1} \leq \theta \leq x_{(1)}$.

最大似然估计

- 总体为 $U(\theta, (k+1)\theta)$, $\theta > 0$, 求 θ 的最大似然估计。
- 似然函数 $L(\theta) = \frac{1}{(k\theta)^n} I_{\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta}$.
- 让似然函数大, θ 应该尽可能的小。由 $\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta$, 有 $\frac{x_{(n)}}{k+1} \leq \theta \leq x_{(1)}$.
- 所以最大似然估计为 $\frac{x_{(n)}}{k+1}$.

最大似然估计

- 总体为 $U(\theta, (k+1)\theta)$, $\theta > 0$, 求 θ 的最大似然估计。
- 似然函数 $L(\theta) = \frac{1}{(k\theta)^n} I_{\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta}$.
- 让似然函数大, θ 应该尽可能的小。由 $\theta \leq x_{(1)} \leq x_{(n)} \theta(k+1)\theta$, 有 $\frac{x_{(n)}}{k+1} \leq \theta \leq x_{(1)}$.
- 所以最大似然估计为 $\frac{x_{(n)}}{k+1}$.
- 若总体 X 的密度函数如下:

$$f(x; \theta) = \begin{cases} 1, & \text{if } \theta = 0, 0 < x < 1; \\ \frac{1}{2\sqrt{x}}, & \text{if } \theta = 1, 0 < x < 1; \\ 0, & \text{else.} \end{cases}$$

求 θ 的最大似然估计。

最大似然估计的函数不变性

- 函数不变性：如果 $\hat{\theta}$ 是 θ 的最大似然估计，则对任一函数 $g(\theta)$ ，其最大似然估计为 $g(\hat{\theta})$.

最大似然估计的函数不变性

- 函数不变性：如果 $\hat{\theta}$ 是 θ 的最大似然估计，则对任一函数 $g(\theta)$ ，其最大似然估计为 $g(\hat{\theta})$.
 $\theta = \hat{\theta}(x_1, \dots, x_n)$ 时似然函数 $L(x_1, \dots, x_n; \theta)$ 取到最大，也就是说 $g(\theta) = g(\hat{\theta})$ 时似然函数 $\bar{L}(x_1, \dots, x_n; g(\theta)) = L(x_1, \dots, x_n; \theta)$ 时取到最大。

最大似然估计的函数不变性

- 函数不变性：如果 $\hat{\theta}$ 是 θ 的最大似然估计，则对任一函数 $g(\theta)$ ，其最大似然估计为 $g(\hat{\theta})$.
 $\theta = \hat{\theta}(x_1, \dots, x_n)$ 时似然函数 $L(x_1, \dots, x_n; \theta)$ 取到最大，也就是说 $g(\theta) = g(\hat{\theta})$ 时似然函数 $\bar{L}(x_1, \dots, x_n; g(\theta)) = L(x_1, \dots, x_n; \theta)$ 时取到最大。
- 总体为 $N(\mu, \sigma^2)$ ， $\hat{\mu} = \bar{x}$ ， $\hat{\sigma}^2 = s_n^2$ 分别为 μ 和 σ^2 的最大似然估计。

最大似然估计的函数不变性

- 函数不变性：如果 $\hat{\theta}$ 是 θ 的最大似然估计，则对任一函数 $g(\theta)$ ，其最大似然估计为 $g(\hat{\theta})$.
 $\theta = \hat{\theta}(x_1, \dots, x_n)$ 时似然函数 $L(x_1, \dots, x_n; \theta)$ 取到最大，也就是说 $g(\theta) = g(\hat{\theta})$ 时似然函数 $\bar{L}(x_1, \dots, x_n; g(\theta)) = L(x_1, \dots, x_n; \theta)$ 时取到最大。
- 总体为 $N(\mu, \sigma^2)$ ， $\hat{\mu} = \bar{x}$ ， $\hat{\sigma}^2 = s_n^2$ 分别为 μ 和 σ^2 的最大似然估计。则
 - 标准差 σ 的最大似然估计为 $\hat{\sigma} = s_n$.
 - 概率 $P(X < 3) = \Phi(\frac{3-\mu}{\sigma})$ 的最大似然估计为 $\Phi(\frac{3-\bar{x}}{s_n})$.
 - 总体的 0.9 分位数 $x_{0.9} = \mu + \sigma u_{0.9}$ ，它的最大似然估计为 $\bar{x} + u_{0.9} s_n$.

最大似然估计的渐进正态性

- 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐进正态的, 如果存在趋向于 0 的非负常数序列 $\sigma_n(\theta)$, 使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布。也称 $\hat{\theta}_n$ 服从渐进正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$. $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐进方差。

最大似然估计的渐进正态性

- 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐进正态的, 如果存在趋向于 0 的非负常数序列 $\sigma_n(\theta)$, 使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布。也称 $\hat{\theta}_n$ 服从渐进正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$. $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐进方差。
- 定理: 若总体有密度函数 $p(x; \theta)$, $\partial_\theta^i \ln p(x; \theta)$, $i = 1, 2, 3$ 均存在 (关于未知参数三阶可导), 且满足

$$\sup_{\theta} \left\{ \int_{-\infty}^{\infty} (|\partial_\theta p| + |\partial_\theta^2 p|) dx, \quad E|\partial_\theta^3 \ln p| \right\} < \infty.$$

最大似然估计的渐进正态性

- 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐进正态的, 如果存在趋向于 0 的非负常数序列 $\sigma_n(\theta)$, 使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布。也称 $\hat{\theta}_n$ 服从渐进正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$. $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐进方差。
- 定理: 若总体有密度函数 $p(x; \theta)$, $\partial_\theta^i \ln p(x; \theta)$, $i = 1, 2, 3$ 均存在 (关于未知参数三阶可导), 且满足

$$\sup_{\theta} \left\{ \int_{-\infty}^{\infty} (|\partial_\theta p| + |\partial_\theta^2 p|) dx, \quad E|\partial_\theta^3 \ln p| \right\} < \infty.$$

$$\text{同时 } 0 < I(\theta) := \int_{-\infty}^{\infty} (\partial_\theta \ln p)^2 p(x; \theta) dx < \infty.$$

最大似然估计的渐进正态性

- 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐进正态的, 如果存在趋向于 0 的非负常数序列 $\sigma_n(\theta)$, 使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布。也称 $\hat{\theta}_n$ 服从渐进正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$. $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐进方差。
- 定理: 若总体有密度函数 $p(x; \theta)$, $\partial_\theta^i \ln p(x; \theta)$, $i = 1, 2, 3$ 均存在 (关于未知参数三阶可导), 且满足

$$\sup_{\theta} \left\{ \int_{-\infty}^{\infty} (|\partial_\theta p| + |\partial_\theta^2 p|) dx, \quad E|\partial_\theta^3 \ln p| \right\} < \infty.$$

同时 $0 < I(\theta) := \int_{-\infty}^{\infty} (\partial_\theta \ln p)^2 p(x; \theta) dx < \infty$. 则存在参数 θ 的最大似然估计

$$\hat{\theta}_n = \hat{\theta}(x_1, \dots, x_n) \sim AN\left(\theta, \frac{1}{nI(\theta)}\right).$$

最大似然估计的渐进正态性

- 参数 θ 的相合估计 $\hat{\theta}_n$ 称为渐进正态的, 如果存在趋向于 0 的非负常数序列 $\sigma_n(\theta)$, 使得 $\frac{\hat{\theta}_n - \theta}{\sigma_n(\theta)}$ 依分布收敛于标准正态分布。也称 $\hat{\theta}_n$ 服从渐进正态分布 $N(\theta, \sigma_n^2(\theta))$, 记为 $\hat{\theta}_n \sim AN(\theta, \sigma_n^2(\theta))$. $\sigma_n^2(\theta)$ 称为 $\hat{\theta}_n$ 的渐进方差。
- 定理: 若总体有密度函数 $p(x; \theta)$, $\partial_\theta^i \ln p(x; \theta)$, $i = 1, 2, 3$ 均存在 (关于未知参数三阶可导), 且满足

$$\sup_{\theta} \left\{ \int_{-\infty}^{\infty} (|\partial_\theta p| + |\partial_\theta^2 p|) dx, \quad E|\partial_\theta^3 \ln p| \right\} < \infty.$$

同时 $0 < I(\theta) := \int_{-\infty}^{\infty} (\partial_\theta \ln p)^2 p(x; \theta) dx < \infty$. 则存在参数 θ 的最大似然估计

$$\hat{\theta}_n = \hat{\theta}(x_1, \dots, x_n) \sim AN\left(\theta, \frac{1}{nI(\theta)}\right).$$

$I(\theta) = E\left[(\partial_\theta \ln p(x; \theta))^2\right]$ 为费希尔信息量或 Fisher 熵。

- 总体的概率函数 $p(x; \theta)$, 且 $\partial_{\theta}^2 p(x, \theta)$ 存在, 则

$$I(\theta) = E[(\partial_{\theta} \ln p(x; \theta))^2] = -E[\partial_{\theta}^2 \ln p(x; \theta)].$$

- 总体的概率函数 $p(x; \theta)$, 且 $\partial_\theta^2 p(x; \theta)$ 存在, 则

$$I(\theta) = E[(\partial_\theta \ln p(x; \theta))^2] = -E[\partial_\theta^2 \ln p(x; \theta)].$$

- 令 $S_\theta = \partial_\theta \ln p(x; \theta)$, 则

$$E(S_\theta) = \int \frac{1}{p(x; \theta)} \partial_\theta p(x; \theta) p(x; \theta) dx = \partial_\theta \int p(x; \theta) dx = 0$$

- 总体的概率函数 $p(x; \theta)$, 且 $\partial_\theta^2 p(x, \theta)$ 存在, 则

$$I(\theta) = E[(\partial_\theta \ln p(x; \theta))^2] = -E[\partial_\theta^2 \ln p(x; \theta)].$$

- 令 $S_\theta = \partial_\theta \ln p(x; \theta)$, 则

$$E(S_\theta) = \int \frac{1}{p(x; \theta)} \partial_\theta p(x; \theta) p(x; \theta) dx = \partial_\theta \int p(x; \theta) dx = 0$$

$$\begin{aligned} 0 &= \partial_\theta E(S_\theta) = \int [\partial_\theta S_\theta p(x; \theta) + S_\theta \partial_\theta p(x; \theta)] dx \\ &= \int [\partial_\theta^2 \ln p(x; \theta) p(x; \theta) + (\partial_\theta \ln p(x; \theta))^2 p(x; \theta)] dx \\ &= E[\partial_\theta^2 \ln p(x; \theta)] + E(\partial_\theta \ln p(x; \theta))^2. \end{aligned}$$

最大似然估计的渐近正态性：大概的证明

① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.

最大似然估计的渐近正态性：大概的证明

- ① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.
- ② 泰勒展开: $l'(\hat{\theta}) = l'(\theta) + l''(\theta)(\hat{\theta} - \theta) + \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 + \dots$

最大似然估计的渐近正态性：大概的证明

- ① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.
- ② 泰勒展开: $l'(\hat{\theta}) = l'(\theta) + l''(\theta)(\hat{\theta} - \theta) + \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 + \dots$
- ③ $-l''(\theta)(\hat{\theta} - \theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 = l'(\theta) \Rightarrow (\hat{\theta} - \theta) = \frac{l'(\theta)}{-l''(\theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)}$.

最大似然估计的渐近正态性：大概的证明

- ① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.
- ② 泰勒展开: $l'(\hat{\theta}) = l'(\theta) + l''(\theta)(\hat{\theta} - \theta) + \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 + \dots$
- ③ $-l''(\theta)(\hat{\theta} - \theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 = l'(\theta) \Rightarrow (\hat{\theta} - \theta) = \frac{l'(\theta)}{-l''(\theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)}$.
- ④ 两边都乘上 \sqrt{n} 有: $\sqrt{n}(\hat{\theta} - \theta) = \frac{\frac{1}{\sqrt{n}}l'(\theta)}{-\frac{1}{n}l''(\theta) - \frac{l'''(\theta)}{2n}(\hat{\theta} - \theta)}$.
- ⑤ 由中心极限定理
$$\frac{1}{\sqrt{n}}l'(\theta) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \partial_{\theta} \log(p(x_i; \theta)) \rightarrow N(0, I(\theta))$$

最大似然估计的渐近正态性：大概的证明

- ① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.
- ② 泰勒展开: $l'(\hat{\theta}) = l'(\theta) + l''(\theta)(\hat{\theta} - \theta) + \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 + \dots$
- ③ $-l''(\theta)(\hat{\theta} - \theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 = l'(\theta) \Rightarrow (\hat{\theta} - \theta) = \frac{l'(\theta)}{-l''(\theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)}$.
- ④ 两边都乘上 \sqrt{n} 有: $\sqrt{n}(\hat{\theta} - \theta) = \frac{\frac{1}{\sqrt{n}}l'(\theta)}{-\frac{1}{n}l''(\theta) - \frac{l'''(\theta)}{2n}(\hat{\theta} - \theta)}$.
- ⑤ 由中心极限定理
 $\frac{1}{\sqrt{n}}l'(\theta) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \partial_{\theta} \log(p(x_i; \theta)) \rightarrow N(0, I(\theta))$
- ⑥ 由大数定律 $-\frac{l''(\theta)}{n} \rightarrow I(\theta)$, $-\frac{l'''(\theta)}{2n}(\hat{\theta} - \theta) \rightarrow 0$.

最大似然估计的渐近正态性：大概的证明

- ① $l(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$. $\hat{\theta}$ 是最大似然估计, 则 $l'(\hat{\theta}) = 0$.
- ② 泰勒展开: $l'(\hat{\theta}) = l'(\theta) + l''(\theta)(\hat{\theta} - \theta) + \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 + \dots$
- ③ $-l''(\theta)(\hat{\theta} - \theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)^2 = l'(\theta) \Rightarrow (\hat{\theta} - \theta) = \frac{l'(\theta)}{-l''(\theta) - \frac{l'''(\theta)}{2}(\hat{\theta} - \theta)}$.
- ④ 两边都乘上 \sqrt{n} 有: $\sqrt{n}(\hat{\theta} - \theta) = \frac{\frac{1}{\sqrt{n}}l'(\theta)}{-\frac{1}{n}l''(\theta) - \frac{l'''(\theta)}{2n}(\hat{\theta} - \theta)}$.
- ⑤ 由中心极限定理
$$\frac{1}{\sqrt{n}}l'(\theta) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \partial_{\theta} \log(p(x_i; \theta)) \rightarrow N(0, I(\theta))$$
- ⑥ 由大数定律 $-\frac{l''(\theta)}{n} \rightarrow I(\theta)$, $-\frac{l'''(\theta)}{2n}(\hat{\theta} - \theta) \rightarrow 0$.
- ⑦ 所以 $\sqrt{n}(\hat{\theta} - \theta) \rightarrow N(0, \frac{1}{I(\theta)})$.

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

$$I(\mu) = E\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{1}{\sigma^2}$$

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

$$I(\mu) = E\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{1}{\sigma^2} \Rightarrow \hat{\mu} \sim AN(\mu, \sigma^2/n).$$

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

$$I(\mu) = E\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{1}{\sigma^2} \Rightarrow \hat{\mu} \sim AN(\mu, \sigma^2/n).$$

- 在 μ 已知时, σ 的 MLE 为

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \sim AN\left(\sigma, \frac{16\sigma^2}{27n}\right).$$

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

$$I(\mu) = E\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{1}{\sigma^2} \Rightarrow \hat{\mu} \sim AN(\mu, \sigma^2/n).$$

- 在 μ 已知时, σ 的 MLE 为

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \sim AN\left(\sigma, \frac{16\sigma^2}{27n}\right).$$

$$\partial_{\sigma} \ln p = \frac{1}{\sigma} + \frac{(x - \mu)^2}{4\sigma^3}$$

最大似然估计的渐进正态性

- 总体为 $N(\mu, \sigma^2)$,
- 当 σ^2 已知时, μ 的最大似然估计为 $\hat{\mu} = \bar{x}$, 则 $\hat{\mu}$ 服从渐进正态分布。关于 μ 的费希尔信息量为 $I(\mu)$,

$$\partial_{\mu} \ln p(x) = \partial_{\mu} \left(\ln \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \right) = \frac{x - \mu}{\sigma^2}.$$

$$I(\mu) = E\left(\frac{x - \mu}{\sigma^2}\right)^2 = \frac{1}{\sigma^2} \Rightarrow \hat{\mu} \sim AN(\mu, \sigma^2/n).$$

- 在 μ 已知时, σ 的 MLE 为

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2} \sim AN\left(\sigma, \frac{16\sigma^2}{27n}\right).$$

$$\partial_{\sigma} \ln p = \frac{1}{\sigma} + \frac{(x - \mu)^2}{4\sigma^3} \Rightarrow I(\sigma) = E\left[\frac{1}{16\sigma^2} (4 + \left(\frac{x - \mu}{\sigma}\right)^2)^2\right] = \frac{27}{16\sigma^2}$$

最大似然估计的渐进正态性

- 总体为参数为 $\lambda > 0$ 的泊松分布：
$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$$

最大似然估计的渐进正态性

- 总体为参数为 $\lambda > 0$ 的泊松分布:

$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$ 似然函数为

$$L(\lambda) = \ln \left(\frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda} \right) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \ln \prod_{i=1}^n x_i!.$$

最大似然估计的渐进正态性

- 总体为参数为 $\lambda > 0$ 的泊松分布:

$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$ 似然函数为

$$L(\lambda) = \ln \left(\frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda} \right) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \ln \prod_{i=1}^n x_i!.$$

$$\partial_{\lambda} L(\lambda) = -n + \frac{1}{\lambda} n\bar{x} = 0 \Rightarrow \hat{\lambda} = \bar{x}.$$

最大似然估计的渐进正态性

- 总体为参数为 $\lambda > 0$ 的泊松分布:

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots \text{ 似然函数为}$$

$$L(\lambda) = \ln \left(\frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} e^{-n\lambda} \right) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \ln \prod_{i=1}^n x_i!.$$

$$\partial_\lambda L(\lambda) = -n + \frac{1}{\lambda} n\bar{x} = 0 \Rightarrow \hat{\lambda} = \bar{x}.$$

费希尔信息量 $I(\lambda)$ 为

$$\partial_\lambda \ln p(\lambda, k) = \partial_\lambda (k \ln \lambda - \lambda - \ln k) = \frac{k}{\lambda} - 1$$

$$\Rightarrow I(\lambda) = E \frac{(k - \lambda)^2}{\lambda^2} = \frac{1}{\lambda}$$

- $\hat{\lambda} \sim AN(\lambda, \frac{\lambda}{n})$, 这也和中心极限定理相符合。

最大似然估计的渐进正态性

- 总体分布为指数分布 $Exp(\frac{1}{\lambda})$, $p(\lambda, x) = \frac{1}{\lambda} e^{-\frac{1}{\lambda}x}$.
- $\frac{1}{\theta}$ 的最大似然估计为 $\frac{1}{\bar{x}}$, 所以 θ 的为 \bar{x} .
- 费希尔信息量:

$$\partial_{\lambda}(\ln p) = \partial_{\lambda}(-\ln \theta - \frac{x}{\theta}) = -\frac{1}{\theta} + \frac{x}{\theta^2} = \frac{x - \theta}{\theta^2}.$$

$$I(\theta) = E\left(\frac{x - \theta}{\theta^2}\right)^2 = \frac{Var(X)}{\theta^4} = \frac{1}{\theta^2}.$$

最大似然估计的渐进正态性

- 总体分布为指数分布 $Exp(\frac{1}{\lambda})$, $p(\lambda, x) = \frac{1}{\lambda} e^{-\frac{1}{\lambda}x}$.
- $\frac{1}{\theta}$ 的最大似然估计为 $\frac{1}{\bar{x}}$, 所以 θ 的为 \bar{x} .
- 费希尔信息量:

$$\partial_{\lambda}(\ln p) = \partial_{\lambda}(-\ln \theta - \frac{x}{\theta}) = -\frac{1}{\theta} + \frac{x}{\theta^2} = \frac{x - \theta}{\theta^2}.$$

$$I(\theta) = E\left(\frac{x - \theta}{\theta^2}\right)^2 = \frac{Var(X)}{\theta^4} = \frac{1}{\theta^2}.$$

- $\hat{\theta} = \bar{x} \sim AN(\theta, \frac{\theta^2}{n})$. 和中心极限定理相符。

矩估计和最大似然估计

- 设某一个试验有三种可能的情况，其发生的概率分别为

$$p_1 = \theta^2, \quad p_2 = 2\theta(1 - \theta), \quad p_3 = (1 - \theta)^2$$

有 n 次试验，三种情况发生的次数分别为 n_1, n_2, n_3 .

- 矩估计：有三种可能 $\theta = \sqrt{p_1}$, $\theta = 1 - \sqrt{p_3}$, $\theta = p_1 + \frac{p_2}{2}$, 即

$$\hat{\theta}_1 = \sqrt{n_1/n}, \quad \hat{\theta}_2 = 1 - \sqrt{n_3/n}, \quad \hat{\theta}_3 = n_1/n + n_2/2/n.$$

- 最大似然估计： $L(\theta) = \ln(\theta^{2n_1}(2\theta(1 - \theta))^{n_2}(1 - \theta)^{2(n - n_1 - n_2)})$.
 $\partial_\theta L(\theta) = \frac{2n_1 + n_2}{\theta} - \frac{2n - 2n_1 - n_2}{1 - \theta} = 0$.

矩估计和最大似然估计

- 设某一个试验有三种可能的情况，其发生的概率分别为

$$p_1 = \theta^2, \quad p_2 = 2\theta(1 - \theta), \quad p_3 = (1 - \theta)^2$$

有 n 次试验，三种情况发生的次数分别为 n_1, n_2, n_3 .

- 矩估计：有三种可能 $\theta = \sqrt{p_1}$, $\theta = 1 - \sqrt{p_3}$, $\theta = p_1 + \frac{p_2}{2}$, 即

$$\hat{\theta}_1 = \sqrt{n_1/n}, \quad \hat{\theta}_2 = 1 - \sqrt{n_3/n}, \quad \hat{\theta}_3 = n_1/n + n_2/2/n.$$

- 最大似然估计： $L(\theta) = \ln(\theta^{2n_1}(2\theta(1 - \theta))^{n_2}(1 - \theta)^{2(n - n_1 - n_2)})$.
 $\partial_{\theta} L(\theta) = \frac{2n_1 + n_2}{\theta} - \frac{2n - 2n_1 - n_2}{1 - \theta} = 0$. $\hat{\theta} = (2n_1 + n_2)/n$.

矩估计和最大似然估计

- 设某一个试验有三种可能的情况，其发生的概率分别为

$$p_1 = \theta^2, \quad p_2 = 2\theta(1 - \theta), \quad p_3 = (1 - \theta)^2$$

有 n 次试验，三种情况发生的次数分别为 n_1, n_2, n_3 .

- 矩估计：有三种可能 $\theta = \sqrt{p_1}$, $\theta = 1 - \sqrt{p_3}$, $\theta = p_1 + \frac{p_2}{2}$, 即

$$\hat{\theta}_1 = \sqrt{n_1/n}, \quad \hat{\theta}_2 = 1 - \sqrt{n_3/n}, \quad \hat{\theta}_3 = n_1/n + n_2/2n.$$

- 最大似然估计： $L(\theta) = \ln(\theta^{2n_1}(2\theta(1 - \theta))^{n_2}(1 - \theta)^{2(n - n_1 - n_2)})$.

$$\partial_{\theta} L(\theta) = \frac{2n_1 + n_2}{\theta} - \frac{2n - 2n_1 - n_2}{1 - \theta} = 0. \quad \hat{\theta} = (2n_1 + n_2)/n.$$

$$\hat{\theta}_1 \rightarrow N\left(\theta, \frac{1 - \theta^2}{4n}\right), \quad \hat{\theta}_2 \rightarrow N\left(\theta, \frac{1 - (1 - \theta)^2}{4n}\right), \quad \hat{\theta}_3 \rightarrow N\left(\theta, \frac{\theta(1 - \theta)}{2n}\right)$$

- $\hat{\theta}$ 为 θ 的一个统计估计量, 则该估计量的均方误差为

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

- $\hat{\theta}$ 为 θ 的一个统计估计量, 则该估计量的均方误差为

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

$$\begin{aligned} MSE(\hat{\theta}) &= E[(\hat{\theta} - E\hat{\theta}) + E\hat{\theta} - \theta]^2 \\ &= E(\hat{\theta} - E\hat{\theta})^2 + (E\hat{\theta} - \theta)^2 + 2E[(\hat{\theta} - E\hat{\theta})(E\hat{\theta} - \theta)] \\ &= Var(\hat{\theta}) + (E\hat{\theta} - \theta)^2. \end{aligned}$$

- $\hat{\theta}$ 为 θ 的一个统计估计量, 则该估计量的均方误差为

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

$$\begin{aligned} MSE(\hat{\theta}) &= E[(\hat{\theta} - E\hat{\theta}) + E\hat{\theta} - \theta]^2 \\ &= E(\hat{\theta} - E\hat{\theta})^2 + (E\hat{\theta} - \theta)^2 + 2E[(\hat{\theta} - E\hat{\theta})(E\hat{\theta} - \theta)] \\ &= Var(\hat{\theta}) + (E\hat{\theta} - \theta)^2. \end{aligned}$$

- 均方误差由点估计统计量的方差和估计偏差的平方组成。一般而言, 均方误差越小, 估计量越好。

均方误差

- 总体为均匀分布 $U(0, \theta)$, θ 的一个无偏估计为 $\hat{\theta} = \frac{n+1}{n}x_{(n)}$, 它的均方误差为

$$MSE(\hat{\theta}) = Var(\hat{\theta}) = \frac{\theta^2}{n(n+2)}.$$

均方误差

- 总体为均匀分布 $U(0, \theta)$, θ 的一个无偏估计为 $\hat{\theta} = \frac{n+1}{n}x_{(n)}$, 它的均方误差为

$$MSE(\hat{\theta}) = Var(\hat{\theta}) = \frac{\theta^2}{n(n+2)}.$$

- 考虑 $\hat{\theta}_\alpha = \alpha x_{(n)}$, 其均方误差为

$$\begin{aligned} MSE(\hat{\theta}_\alpha) &= Var(\alpha x_{(n)}) + (\alpha Ex_{(n)} - \theta)^2 \\ &= \frac{\alpha^2 n \theta^2}{(n+1)^2(n+2)} + \left(\frac{n\alpha\theta}{n+1} - \theta\right)^2. \end{aligned}$$

均方误差

- 总体为均匀分布 $U(0, \theta)$, θ 的一个无偏估计为 $\hat{\theta} = \frac{n+1}{n}x_{(n)}$, 它的均方误差为

$$MSE(\hat{\theta}) = Var(\hat{\theta}) = \frac{\theta^2}{n(n+2)}.$$

- 考虑 $\hat{\theta}_\alpha = \alpha x_{(n)}$, 其均方误差为

$$\begin{aligned} MSE(\hat{\theta}_\alpha) &= Var(\alpha x_{(n)}) + (\alpha Ex_{(n)} - \theta)^2 \\ &= \frac{\alpha^2 n \theta^2}{(n+1)^2(n+2)} + \left(\frac{n\alpha\theta}{n+1} - \theta\right)^2. \end{aligned}$$

- 当 $\alpha = \frac{n+2}{n+1}$ 时, 均方误差最小, 为 $\frac{\theta^2}{(n+1)^2}$. 不是无偏估计!

一致最小方差无偏估计

- 定义：设 $\hat{\theta}$ 是未知参数 θ 的无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，都有

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$$

则称 $\hat{\theta}$ 的一致最小方差无偏估计，简介为 *UMVUE*.

一致最小方差无偏估计

- 定义：设 $\hat{\theta}$ 是未知参数 θ 的无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，都有

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$$

则称 $\hat{\theta}$ 的一致最小方差无偏估计，简介为 *UMVUE*.

- 定理： $X = (x_1, \dots, x_n)$ 是来自某总体的一个样本， $\hat{\theta}$ 是 θ 的一个无偏估计， $\text{Var}(\hat{\theta}) < \infty$ ，则 $\hat{\theta}$ 是 θ 的 *UMVUE* 的充分必要条件为：对任意满足 $E(\varphi(X)) = 0$ ， $\text{Var}(\varphi(X)) < \infty$ 的随机变量 $\varphi(X)$ ，都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0.$$

一致最小方差无偏估计

- 定义：设 $\hat{\theta}$ 是未知参数 θ 的无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，都有

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$$

则称 $\hat{\theta}$ 的一致最小方差无偏估计，简介为 *UMVUE*.

- 定理： $X = (x_1, \dots, x_n)$ 是来自某总体的一个样本， $\hat{\theta}$ 是 θ 的一个无偏估计， $\text{Var}(\hat{\theta}) < \infty$ ，则 $\hat{\theta}$ 是 θ 的 *UMVUE* 的充分必要条件为：对任意满足 $E(\varphi(X)) = 0$ ， $\text{Var}(\varphi(X)) < \infty$ 的随机变量 $\varphi(X)$ ，都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0.$$

- 充分性：对于 θ 的任一个无偏估计 $\tilde{\theta}$ ，令 $\varphi = \hat{\theta} - \tilde{\theta}$ ，则 $E(\varphi) = 0$.

一致最小方差无偏估计

- 定义：设 $\hat{\theta}$ 是未知参数 θ 的无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，都有

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$$

则称 $\hat{\theta}$ 的一致最小方差无偏估计，简介为 *UMVUE*.

- 定理： $X = (x_1, \dots, x_n)$ 是来自某总体的一个样本， $\hat{\theta}$ 是 θ 的一个无偏估计， $\text{Var}(\hat{\theta}) < \infty$ ，则 $\hat{\theta}$ 是 θ 的 *UMVUE* 的充分必要条件为：对任意满足 $E(\varphi(X)) = 0$ ， $\text{Var}(\varphi(X)) < \infty$ 的随机变量 $\varphi(X)$ ，都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0.$$

- 充分性：对于 θ 的任一个无偏估计 $\tilde{\theta}$ ，令 $\varphi = \hat{\theta} - \tilde{\theta}$ ，则 $E(\varphi) = 0$.
$$\text{Var}(\tilde{\theta}) = E(\tilde{\theta} - \hat{\theta} + \hat{\theta} - \theta)^2 = E(\varphi^2) + \text{Var}(\hat{\theta}) + 2\text{Cov}(\varphi, \hat{\theta}) \geq \text{Var}(\hat{\theta}).$$

一致最小方差无偏估计

- 必要性：反证法。假设 $\hat{\theta}$ 是 θ 的 UMVUE, $\varphi(X)$ 满足

$$E(\varphi(X)) = 0, \quad \text{Var}(\varphi(X)) < \infty, \quad \text{Cov}_{\theta}(\varphi(X), \hat{\theta}) = a \neq 0.$$

一致最小方差无偏估计

- 必要性：反证法。假设 $\hat{\theta}$ 是 θ 的 UMVUE, $\varphi(X)$ 满足

$$E(\varphi(X)) = 0, \quad \text{Var}(\varphi(X)) < \infty, \quad \text{Cov}_{\theta}(\varphi(X), \hat{\theta}) = a \neq 0.$$

取 $b = \frac{-a}{\text{Var}(\varphi(X))} \neq 0$, 令 $\tilde{\theta} = \hat{\theta} + b\varphi(X)$, 则

一致最小方差无偏估计

- 必要性：反证法。假设 $\hat{\theta}$ 是 θ 的 UMVUE, $\varphi(X)$ 满足

$$E(\varphi(X)) = 0, \quad \text{Var}(\varphi(X)) < \infty, \quad \text{Cov}_{\theta}(\varphi(X), \hat{\theta}) = a \neq 0.$$

取 $b = \frac{-a}{\text{Var}(\varphi(X))} \neq 0$, 令 $\tilde{\theta} = \hat{\theta} + b\varphi(X)$, 则

$$\begin{aligned} \text{Var}(\tilde{\theta}) &= E(\hat{\theta} + b\varphi - \theta)^2 \\ &= E(\hat{\theta} - \theta)^2 + b^2 E(\varphi^2) + 2bE(\hat{\theta} - \theta)\varphi) \\ &= \text{Var}(\hat{\theta}) + b^2 \text{Var}(\varphi) + 2ab \\ &= \text{Var}(\hat{\theta}) - ab < \text{Var}(\hat{\theta}). \end{aligned}$$

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

$$E(\varphi) = \int_{R^n} \varphi(x_1, \dots, x_n) \frac{1}{\theta^n} e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

$$\text{即有 } \int_{R^n} \varphi(X) e^{-n\bar{x}/\theta} dX = 0.$$

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

$$E(\varphi) = \int_{R^n} \varphi(x_1, \dots, x_n) \frac{1}{\theta^n} e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

即有 $\int_{R^n} \varphi(X) e^{-n\bar{x}/\theta} dX = 0$. 对 θ 求导,

$$\int_{R^n} \frac{n\bar{x}}{\theta^2} \varphi(X) e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

$$E(\varphi) = \int_{R^n} \varphi(x_1, \dots, x_n) \frac{1}{\theta^n} e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

即有 $\int_{R^n} \varphi(X) e^{-n\bar{x}/\theta} dX = 0$. 对 θ 求导,

$$\int_{R^n} \frac{n\bar{x}}{\theta^2} \varphi(X) e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

$$E(\bar{x}\varphi(X)) = 0 \Rightarrow Cov(\bar{x}, \varphi) = E(\bar{x}\varphi(X)) - E(\bar{x})E(\varphi(X)) = 0.$$

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

$$E(\varphi) = \int_{R^n} \varphi(x_1, \dots, x_n) \frac{1}{\theta^n} e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

即有 $\int_{R^n} \varphi(X) e^{-n\bar{x}/\theta} dX = 0$. 对 θ 求导,

$$\int_{R^n} \frac{n\bar{x}}{\theta^2} \varphi(X) e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

$$E(\bar{x}\varphi(X)) = 0 \Rightarrow Cov(\bar{x}, \varphi) = E(\bar{x}\varphi(X)) - E(\bar{x})E(\varphi(X)) = 0.$$

- \bar{x} 为 UMVUE.

一致最小方差无偏估计

- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $\theta > 0$, $x > 0$.
- $\hat{\theta} = \bar{x}$ 为 θ 的无偏估计, 令 $E\varphi(x_1, \dots, x_n) = 0$, 即

$$E(\varphi) = \int_{R^n} \varphi(x_1, \dots, x_n) \frac{1}{\theta^n} e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

即有 $\int_{R^n} \varphi(X) e^{-n\bar{x}/\theta} dX = 0$. 对 θ 求导,

$$\int_{R^n} \frac{n\bar{x}}{\theta^2} \varphi(X) e^{-\frac{x_1 + \dots + x_n}{\theta}} dX = 0.$$

$$E(\bar{x}\varphi(X)) = 0 \Rightarrow Cov(\bar{x}, \varphi) = E(\bar{x}\varphi(X)) - E(\bar{x})E(\varphi(X)) = 0.$$

- \bar{x} 为 UMVUE. 同时 \bar{x} 也是充分统计量。

一致最小方差无偏估计

- 总体为正态分布 $N(\mu, \sigma^2)$, $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = s^2$ 是 μ, σ^2 的无偏估计。

一致最小方差无偏估计

- 总体为正态分布 $N(\mu, \sigma^2)$, $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = s^2$ 是 μ, σ^2 的无偏估计。它们也是 UMVUE.

一致最小方差无偏估计

- 总体为正态分布 $N(\mu, \sigma^2)$, $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = s^2$ 是 μ, σ^2 的无偏估计。它们也是 UMVUE.
- $E(\varphi(x_1, \dots, x_n)) = 0$, 即

$$E(\varphi) = \int \varphi(X) (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + n\bar{x}\frac{\mu}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}} dX = 0.$$

- 对 μ 求导, 得 $E(\frac{n\bar{x}\varphi}{\sigma^2}) = 0$, 即 $E(\bar{x}\varphi) = 0 \rightarrow \text{Cov}(\varphi, \bar{x}) = 0$.

一致最小方差无偏估计

- 总体为正态分布 $N(\mu, \sigma^2)$, $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = s^2$ 是 μ , σ^2 的无偏估计。它们也是 UMVUE.
- $E(\varphi(x_1, \dots, x_n)) = 0$, 即

$$E(\varphi) = \int \varphi(X) (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + n\bar{x}\frac{\mu}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}} dX = 0.$$

- 对 μ 求导, 得 $E(\frac{n\bar{x}\varphi}{\sigma^2}) = 0$, 即 $E(\bar{x}\varphi) = 0 \rightarrow Cov(\varphi, \bar{x}) = 0$.
- 对 μ 求两次导, 得 $E(\bar{x}^2\varphi) = 0$.

一致最小方差无偏估计

- 总体为正态分布 $N(\mu, \sigma^2)$, $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = s^2$ 是 μ , σ^2 的无偏估计。它们也是 UMVUE。
- $E(\varphi(x_1, \dots, x_n)) = 0$, 即

$$E(\varphi) = \int \varphi(X) (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + n\bar{x}\frac{\mu}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}} dX = 0.$$

- 对 μ 求导, 得 $E(\frac{n\bar{x}\varphi}{\sigma^2}) = 0$, 即 $E(\bar{x}\varphi) = 0 \rightarrow \text{Cov}(\varphi, \bar{x}) = 0$.
- 对 μ 求两次导, 得 $E(\bar{x}^2\varphi) = 0$.
- 对 σ^2 求一次导, 得 $E(\varphi \sum_{i=1}^n x_i^2) = 0$, 从而 $E(s^2\varphi) = 0$. 即有 $\text{Cov}(s^2, \varphi) = 0$.
- \bar{x} 和 $\sum_{i=1}^n x_i^2$ 是未知参数向量 (μ, σ^2) 得充分统计量。

充分性与 UMVUE

- 总体函数为 $p(x; \theta)$, x_1, \dots, x_n 是其样本, $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对于 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta}|T)$, 则 $\tilde{\theta}$ 是 θ 的无偏估计, 而且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta}).$$

充分性与 UMVUE

- 总体函数为 $p(x; \theta)$, x_1, \dots, x_n 是其样本, $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对于 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta} | T)$, 则 $\tilde{\theta}$ 是 θ 的无偏估计, 而且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta}).$$

- T 是充分统计量, 所以 $E(\hat{\theta} | T)$ 与未知参数 θ 无关, 同时
$$E(E(\hat{\theta} | T)) = E(\hat{\theta}) = \theta.$$

充分性与 UMVUE

- 总体函数为 $p(x; \theta)$, x_1, \dots, x_n 是其样本, $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对于 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta} | T)$, 则 $\tilde{\theta}$ 是 θ 的无偏估计, 而且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta}).$$

- T 是充分统计量, 所以 $E(\hat{\theta} | T)$ 与未知参数 θ 无关, 同时

$$E(E(\hat{\theta} | T)) = E(\hat{\theta}) = \theta.$$

$$\begin{aligned} \text{Var}(\hat{\theta}) &= E(\hat{\theta} - \tilde{\theta} + \tilde{\theta} - \theta)^2 \\ &= E(\hat{\theta} - \tilde{\theta})^2 + E(\tilde{\theta} - \theta)^2 + 2 \underbrace{E(\hat{\theta} - \tilde{\theta})(\tilde{\theta} - \theta)}_{=0} \\ &= E(\hat{\theta} - \tilde{\theta})^2 + \text{Var}(\tilde{\theta}) \geq \text{Var}(\tilde{\theta}). \end{aligned}$$

充分性与 UMVUE

- 总体函数为 $p(x; \theta)$, x_1, \dots, x_n 是其样本, $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对于 θ 的任一无偏估计 $\hat{\theta}$, 令 $\tilde{\theta} = E(\hat{\theta}|T)$, 则 $\tilde{\theta}$ 是 θ 的无偏估计, 而且

$$\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta}).$$

- T 是充分统计量, 所以 $E(\hat{\theta}|T)$ 与未知参数 θ 无关, 同时

$$E(E(\hat{\theta}|T)) = E(\hat{\theta}) = \theta.$$

$$\begin{aligned}\text{Var}(\hat{\theta}) &= E(\hat{\theta} - \tilde{\theta} + \tilde{\theta} - \theta)^2 \\ &= E(\hat{\theta} - \tilde{\theta})^2 + E(\tilde{\theta} - \theta)^2 + 2 \underbrace{E(\hat{\theta} - \tilde{\theta})(\tilde{\theta} - \theta)}_{=0} \\ &= E(\hat{\theta} - \tilde{\theta})^2 + \text{Var}(\tilde{\theta}) \geq \text{Var}(\tilde{\theta}).\end{aligned}$$

- 如果无偏估计 $\hat{\theta}$ 不是充分统计量 T 的函数, 则可以降低方差。

充分性与 UMVUE

- 总体为 $b(1, p)$, $T = n\bar{x}$ 是 p 的充分估计量, $\theta = p^2$, 考虑

$$\theta_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1, \\ 0, & \text{其他} \end{cases}.$$

- 总体为 $b(1, p)$, $T = n\bar{x}$ 是 p 的充分估计量, $\theta = p^2$, 考虑

$$\theta_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1, \\ 0, & \text{其他} \end{cases}.$$

θ_1 是 θ 的无偏估计量:

$$E(\theta_1) = P(x_1 = 1, x_2 = 1) = p^2 = \theta.$$

充分性与 UMVUE

- 总体为 $b(1, p)$, $T = n\bar{x}$ 是 p 的充分估计量, $\theta = p^2$, 考虑

$$\theta_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1, \\ 0, & \text{其他} \end{cases}.$$

θ_1 是 θ 的无偏估计量:

$$E(\theta_1) = P(x_1 = 1, x_2 = 1) = p^2 = \theta. \text{Var}(\theta_1) = \theta(1 - \theta).$$

充分性与 UMVUE

- 总体为 $b(1, p)$, $T = n\bar{x}$ 是 p 的充分估计量, $\theta = p^2$, 考虑

$$\theta_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1, \\ 0, & \text{其他} \end{cases}.$$

θ_1 是 θ 的无偏估计量:

$$E(\theta_1) = P(x_1 = 1, x_2 = 1) = p^2 = \theta. \text{Var}(\theta_1) = \theta(1 - \theta).$$

$$\begin{aligned} \hat{\theta} &= E(\theta_1 | T = t) = P(\theta_1 = 1 | T = t) \\ &= \frac{P(x_1 = 1, x_2 = 1, T = t)}{P(T = t)} = \frac{p^2 \binom{n-2}{t-2} p^{t-2} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \frac{\binom{n-2}{t-2}}{\binom{n}{t}} = \frac{t(t-1)}{n(n-1)} = \frac{\bar{x}(n\bar{x}-1)}{n-1}. \end{aligned}$$

充分性与 UMVUE

- 总体为 $b(1, p)$, $T = n\bar{x}$ 是 p 的充分估计量, $\theta = p^2$, 考虑

$$\theta_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1, \\ 0, & \text{其他} \end{cases}.$$

θ_1 是 θ 的无偏估计量:

$$E(\theta_1) = P(x_1 = 1, x_2 = 1) = p^2 = \theta. \text{Var}(\theta_1) = \theta(1 - \theta).$$

$$\begin{aligned} \hat{\theta} &= E(\theta_1 | T = t) = P(\theta_1 = 1 | T = t) \\ &= \frac{P(x_1 = 1, x_2 = 1, T = t)}{P(T = t)} = \frac{p^2 \binom{n-2}{t-2} p^{t-2} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} \\ &= \frac{\binom{n-2}{t-2}}{\binom{n}{t}} = \frac{t(t-1)}{n(n-1)} = \frac{\bar{x}(n\bar{x}-1)}{n-1}. \end{aligned}$$

$$E(\hat{\theta}) = \theta, \quad \text{Var}(\hat{\theta}) < \text{Var}(\theta_1).$$

- 总体分布为 $p(x; \theta)$, x_1, \dots, x_n 为该总体的样本, $T = T(x_1, \dots, x_n)$ 是 $g(\theta)$ 的无偏估计, $g(\theta)$ 关于 θ 可微, 即 $g'(\theta)$ 存在; 而且

$$g'(\theta) = \int T(x_1, \dots, x_n) \partial_\theta \left(\prod_{i=1}^n p(x_i; \theta) \right) dX,$$

则有

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)},$$

其中 $I(\theta)$ 是费希尔信息量, $I(\theta) = E(\partial_\theta \ln p(x; \theta))^2$. 若以上不等式的等号成立, 则称 $T = T(x_1, \dots, x_n)$ 为 $g(\theta)$ 的有效估计, 有效估计一定是 UMVUE.

Cramer-Rao 不等式

- $0 = \int \partial_{\theta} p(x_i; \theta) dx_i = \int [\partial_{\theta} \ln p(x_i; \theta)] p(x_i; \theta) dx_i = E[\partial_{\theta} \ln p(x_i; \theta)].$

Cramer-Rao 不等式

- $0 = \int \partial_{\theta} p(x_i; \theta) dx_i = \int [\partial_{\theta} \ln p(x_i; \theta)] p(x_i; \theta) dx_i = E[\partial_{\theta} \ln p(x_i; \theta)].$
- 令 $Z = \partial_{\theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \partial_{\theta} \ln p(x_i; \theta),$

Cramer-Rao 不等式

- $0 = \int \partial_{\theta} p(x_i; \theta) dx_i = \int [\partial_{\theta} \ln p(x_i; \theta)] p(x_i; \theta) dx_i = E[\partial_{\theta} \ln p(x_i; \theta)]$.
- 令 $Z = \partial_{\theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \partial_{\theta} \ln p(x_i; \theta)$, 则

$$EZ = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)] = 0,$$

$$EZ^2 = \sum_{i=1}^n \text{Var}[\partial_{\theta} \ln p(x_i; \theta)] = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)]^2 = nI(\theta).$$

Cramer-Rao 不等式

- $0 = \int \partial_{\theta} p(x_i; \theta) dx_i = \int [\partial_{\theta} \ln p(x_i; \theta)] p(x_i; \theta) dx_i = E[\partial_{\theta} \ln p(x_i; \theta)]$.
- 令 $Z = \partial_{\theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \partial_{\theta} \ln p(x_i; \theta)$, 则

$$EZ = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)] = 0,$$

$$EZ^2 = \sum_{i=1}^n \text{Var}[\partial_{\theta} \ln p(x_i; \theta)] = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)]^2 = nI(\theta).$$

$$\begin{aligned} [g'(\theta)]^2 &= [E(TZ)]^2 = [E((T - g(\theta))Z)]^2 \\ &\leq E[(T - g(\theta))^2] E(Z^2) = \text{Var}(T) \text{Var}(Z) = \text{Var}(T) nI(\theta). \end{aligned}$$

Cramer-Rao 不等式

- $0 = \int \partial_{\theta} p(x_i; \theta) dx_i = \int [\partial_{\theta} \ln p(x_i; \theta)] p(x_i; \theta) dx_i = E[\partial_{\theta} \ln p(x_i; \theta)]$.
- 令 $Z = \partial_{\theta} \ln \prod_{i=1}^n p(x_i; \theta) = \sum_{i=1}^n \partial_{\theta} \ln p(x_i; \theta)$, 则

$$EZ = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)] = 0,$$

$$EZ^2 = \sum_{i=1}^n \text{Var}[\partial_{\theta} \ln p(x_i; \theta)] = \sum_{i=1}^n E[\partial_{\theta} \ln p(x_i; \theta)]^2 = nI(\theta).$$

$$\begin{aligned} [g'(\theta)]^2 &= [E(TZ)]^2 = [E((T - g(\theta))Z)]^2 \\ &\leq E[(T - g(\theta))^2] E(Z^2) = \text{Var}(T) \text{Var}(Z) = \text{Var}(T) nI(\theta). \end{aligned}$$

$$\text{Var}(T) \geq [g'(\theta)]^2 / (nI(\theta)).$$

- 总体为 $p(x: \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$.

- 总体为 $p(x: \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$. 为 $b(1, \theta)$,

有效估计

- 总体为 $p(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$. 为 $b(1, \theta)$, 费希尔信息量为

$$I(\theta) = E[\partial_{\theta} \ln p(x; \theta)]^2 = \frac{1}{\theta^2} \theta + \frac{1}{(1 - \theta)^2} (1 - \theta) = \frac{1}{\theta(1 - \theta)}.$$

有效估计

- 总体为 $p(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$. 为 $b(1, \theta)$, 费希尔信息量为

$$I(\theta) = E[\partial_\theta \ln p(x; \theta)]^2 = \frac{1}{\theta^2}\theta + \frac{1}{(1 - \theta)^2}(1 - \theta) = \frac{1}{\theta(1 - \theta)}.$$

- \bar{x} 是 θ 的无偏估计, 且 $Var(\bar{x}) = \frac{\theta(1-\theta)}{n} = \frac{1}{nI(\theta)}$. 为有效估计

有效估计

- 总体为 $p(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$. 为 $b(1, \theta)$, 费希尔信息量为

$$I(\theta) = E[\partial_\theta \ln p(x; \theta)]^2 = \frac{1}{\theta^2} \theta + \frac{1}{(1 - \theta)^2} (1 - \theta) = \frac{1}{\theta(1 - \theta)}.$$

- \bar{x} 是 θ 的无偏估计, 且 $Var(\bar{x}) = \frac{\theta(1-\theta)}{n} = \frac{1}{nI(\theta)}$. 为有效估计
- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, $x > 0, \theta > 0$. 费希尔信息量为

$$I(\theta) = \int \left(-\frac{1}{\theta} + \frac{x}{\theta^2}\right) \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = \frac{1}{\theta^2}.$$

有效估计

- 总体为 $p(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$. 为 $b(1, \theta)$, 费希尔信息量为

$$I(\theta) = E[\partial_\theta \ln p(x; \theta)]^2 = \frac{1}{\theta^2}\theta + \frac{1}{(1 - \theta)^2}(1 - \theta) = \frac{1}{\theta(1 - \theta)}.$$

- \bar{x} 是 θ 的无偏估计, 且 $Var(\bar{x}) = \frac{\theta(1-\theta)}{n} = \frac{1}{nI(\theta)}$. 为有效估计
- 总体为指数分布 $Exp(\frac{1}{\theta})$, $p(x; \theta) = \frac{1}{\theta}e^{-\frac{x}{\theta}}$, $x > 0, \theta > 0$. 费希尔信息量为

$$I(\theta) = \int \left(-\frac{1}{\theta} + \frac{x}{\theta^2}\right) \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = \frac{1}{\theta^2}.$$

- $Var(\bar{x}) = \frac{\theta^2}{n} = \frac{1}{nI(\theta)}$. 为有效估计。

- 总体为 $N(0, \sigma^2)$, 其费希尔信息量为

$$I(\sigma^2) = E\left[\frac{x^2}{2\sigma^4} - \frac{1}{2\sigma^2}\right]^2 = \frac{1}{4\sigma^4} \text{Var}\left(\frac{x^2}{\sigma^2}\right) = \frac{1}{2\sigma^4}.$$

有效估计

- 总体为 $N(0, \sigma^2)$, 其费希尔信息量为

$$I(\sigma^2) = E\left[\frac{x^2}{2\sigma^4} - \frac{1}{2\sigma^2}\right]^2 = \frac{1}{4\sigma^4} \text{Var}\left(\frac{x^2}{\sigma^2}\right) = \frac{1}{2\sigma^4}.$$

- $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ 是 σ^2 的无偏估计, 而且
$$\text{Var}(\hat{\sigma}^2) = \frac{2\sigma^4}{n} = \frac{1}{nI(\sigma^2)}.$$

有效估计

- 总体为 $N(0, \sigma^2)$, 其费希尔信息量为

$$I(\sigma^2) = E\left[\frac{x^2}{2\sigma^4} - \frac{1}{2\sigma^2}\right]^2 = \frac{1}{4\sigma^4} \text{Var}\left(\frac{x^2}{\sigma^2}\right) = \frac{1}{2\sigma^4}.$$

- $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ 是 σ^2 的无偏估计, 而且

$$\text{Var}(\hat{\sigma}^2) = \frac{2\sigma^4}{n} = \frac{1}{nI(\sigma^2)}.$$

- $\hat{\sigma} = \sqrt{\frac{n}{2}} \frac{\Gamma(n/2)}{\Gamma((n+1)/2)} \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$ 为 σ 的无偏估计。其 C-R 下界为

$$\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{\sigma^2}{2n}.$$

- $\text{Var}(\hat{\sigma}) = \left(\sqrt{\frac{n}{2}} \frac{\Gamma(n/2)}{\Gamma((n+1)/2)}\right)^2 \sigma^2 - \sigma^2 > \frac{\sigma^2}{2n},$

有效估计

- 总体为 $N(0, \sigma^2)$, 其费希尔信息量为

$$I(\sigma^2) = E\left[\frac{x^2}{2\sigma^4} - \frac{1}{2\sigma^2}\right]^2 = \frac{1}{4\sigma^4} \text{Var}\left(\frac{x^2}{\sigma^2}\right) = \frac{1}{2\sigma^4}.$$

- $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ 是 σ^2 的无偏估计, 而且
$$\text{Var}(\hat{\sigma}^2) = \frac{2\sigma^4}{n} = \frac{1}{nI(\sigma^2)}.$$

- $\hat{\sigma} = \sqrt{\frac{n}{2} \frac{\Gamma(n/2)}{\Gamma((n+1)/2)}} \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$ 为 σ 的无偏估计。其 C-R 下界为

$$\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{\sigma^2}{2n}.$$

- $\text{Var}(\hat{\sigma}) = \left(\sqrt{\frac{n}{2} \frac{\Gamma(n/2)}{\Gamma((n+1)/2)}}\right)^2 \sigma^2 - \sigma^2 > \frac{\sigma^2}{2n}$, $\hat{\sigma}$ 是 UMVUE, 但不是有效估计。

有效估计

- 总体为 $N(\mu, 1)$, $T = \bar{x}^2 - \frac{1}{n}$ 为 μ^2 的 UMVUE, 但不是有效估计。
- $E(T) = E(\bar{x}^2) - \frac{1}{n} = [E(\bar{x})]^2 + Var(\bar{x}) - \frac{1}{n} = \mu^2 + \frac{1}{n} - \frac{1}{n} = \mu^2$.

有效估计

- 总体为 $N(\mu, 1)$, $T = \bar{x}^2 - \frac{1}{n}$ 为 μ^2 的 UMVUE, 但不是有效估计。
- $E(T) = E(\bar{x}^2) - \frac{1}{n} = [E(\bar{x})]^2 + \text{Var}(\bar{x}) - \frac{1}{n} = \mu^2 + \frac{1}{n} - \frac{1}{n} = \mu^2$.
- 对于任意的 $E(\varphi(X)) = 0$,

$$E(\bar{x}^2 \varphi) = \int \left(\frac{x_1 + \cdots + x_n}{n} \right)^2 \varphi(X) \frac{e^{-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2}}}{(\sqrt{2\pi})^n} dX = 0$$

所以 $\text{Cov}(T, \varphi) = 0$, T 为 UMVUE.

- $\text{Var}(T) = \text{Var}(\bar{x}^2) = \frac{2}{n^2} + \frac{4}{n}\mu^2$, 费希尔信息量 $I(\mu) = 1$, 于是 C-R 下界为 $\frac{(2\mu)^2}{n}$. 所以 T 不是有效估计。

- 统计推断的基础：总体的信息，样本的信息，

- 统计推断的基础：总体的信息，样本的信息，先验的信息。

- 统计推断的基础：总体的信息，样本的信息，先验的信息。
- 总体的信息：服从何种分布，数学期望、方差为何等等；
- 样本信息：经验分布函数，样本均值，样本方差，统计量等等；
- 先验信息：从以往经验里等到的信息：比如说之前已经做过一轮抽样研究等等。

- 统计推断的基础：总体的信息，样本的信息，先验的信息。
- 总体的信息：服从何种分布，数学期望、方差为何等等；
- 样本信息：经验分布函数，样本均值，样本方差，统计量等等；
- 先验信息：从以往经验里等到的信息：比如说之前已经做过一轮抽样研究等等。
- 我们之前的统计方法都没有用到先验信息。并且假设未知参数是一个常数。

贝叶斯估计

- 统计推断的基础：总体的信息，样本的信息，先验的信息。
- 总体的信息：服从何种分布，数学期望、方差为何等等；
- 样本信息：经验分布函数，样本均值，样本方差，统计量等等；
- 先验信息：从以往经验里等到的信息：比如说之前已经做过一轮抽样研究等等。
- 我们之前的统计方法都没有用到先验信息。并且假设未知参数是一个常数。
- 贝叶斯估计的最大原则是未知参数是一个随机变量，可以用一个概率分布去描述，此分布为先验分布。

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.
- 样本 X 与未知参数 θ 的联合密度函数为 $h(X, \theta) = \frac{h(X, \theta)}{\pi(\theta)} \pi(\theta) = p(X|\theta) \pi(\theta)$.

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.
- 样本 X 与未知参数 θ 的联合密度函数为 $h(X, \theta) = \frac{h(X, \theta)}{\pi(\theta)} \pi(\theta) = p(X|\theta) \pi(\theta)$.
- θ 的后验分布为 $\pi(\theta|X) = \frac{h(X, \theta)}{m(X)} = \frac{p(X|\theta) \pi(\theta)}{\int_{\Theta} p(X|\theta) \pi(\theta) d\theta}$.

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.
- 样本 X 与未知参数 θ 的联合密度函数为 $h(X, \theta) = \frac{h(X, \theta)}{\pi(\theta)} \pi(\theta) = p(X|\theta) \pi(\theta)$.
- θ 的后验分布为 $\pi(\theta|X) = \frac{h(X, \theta)}{m(X)} = \frac{p(X|\theta) \pi(\theta)}{\int_{\Theta} p(X|\theta) \pi(\theta) d\theta}$.
- 由后验分布 $\pi(\theta|X)$ 来估计 θ :
 - 使用后验密度函数的 $\pi(\theta|X)$ 最大值点作为 θ 的估计。

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.
- 样本 X 与未知参数 θ 的联合密度函数为 $h(X, \theta) = \frac{h(X, \theta)}{\pi(\theta)} \pi(\theta) = p(X|\theta) \pi(\theta)$.
- θ 的后验分布为 $\pi(\theta|X) = \frac{h(X, \theta)}{m(X)} = \frac{p(X|\theta) \pi(\theta)}{\int_{\Theta} p(X|\theta) \pi(\theta) d\theta}$.
- 由后验分布 $\pi(\theta|X)$ 来估计 θ :
 - 使用后验密度函数的 $\pi(\theta|X)$ 最大值点作为 θ 的估计。
 - 后验分布的数学期望;

贝叶斯公式的密度函数形式

- 总体含有未知参数 θ , 其在给定 θ 的取值时的条件密度函数 $p(x|\theta)$.
- 参数根据先验信息确定的先验分布为 $\pi(\theta)$.
- 样本 $X = (x_1, \dots, x_n)$ 的联合条件密度函数为 $p(X|\theta_0) = p(x_1, \dots, x_n|\theta_0) = \prod_{i=1}^n p(x_i|\theta_0)$.
- 样本 X 与未知参数 θ 的联合密度函数为 $h(X, \theta) = \frac{h(X, \theta)}{\pi(\theta)} \pi(\theta) = p(X|\theta) \pi(\theta)$.
- θ 的后验分布为 $\pi(\theta|X) = \frac{h(X, \theta)}{m(X)} = \frac{p(X|\theta) \pi(\theta)}{\int_{\Theta} p(X|\theta) \pi(\theta) d\theta}$.
- 由后验分布 $\pi(\theta|X)$ 来估计 θ :
 - 使用后验密度函数的 $\pi(\theta|X)$ 最大值点作为 θ 的估计。
 - 后验分布的数学期望；
 - 后验分布的中位数。

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$.

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。
- X 与 θ 的联合 (密度) 函数为:
$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, \dots, n, \quad 0 < \theta < 1.$$

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。

- X 与 θ 的联合 (密度) 函数为:

$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, \dots, n, \quad 0 < \theta < 1.$$

- X 的边际分布为

$$m(X) = \binom{n}{x} \int_0^1 \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}.$$

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。
- X 与 θ 的联合 (密度) 函数为:
$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, \dots, n, \quad 0 < \theta < 1.$$
- X 的边际分布为
$$m(X) = \binom{n}{x} \int_0^1 \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}.$$
- θ 的后验分布为 $\pi(\theta|x) = \frac{h(x|\theta)}{m(x)} = \frac{\Gamma(n+2)\theta^{x+1-1}(1-\theta)^{n-x+1-1}}{\Gamma(x+1)\Gamma(n-x+1)}.$

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。
- X 与 θ 的联合 (密度) 函数为:
$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, \dots, n, \quad 0 < \theta < 1.$$
- X 的边际分布为
$$m(X) = \binom{n}{x} \int_0^1 \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}.$$
- θ 的后验分布为 $\pi(\theta|x) = \frac{h(x|\theta)}{m(x)} = \frac{\Gamma(n+2)\theta^{x+1-1}(1-\theta)^{n-x+1-1}}{\Gamma(x+1)\Gamma(n-x+1)}.$
- $\theta|x \sim Be(x+1, n-x+1)$, $\hat{\theta} = E(\theta|x) = \frac{x+1}{n+2}.$

贝叶斯估计

- 设某事件发生的概率为 θ , 对试验进行 n 次独立的观测, 其中 A 发生的次数为 X . 则 $X|\theta \sim b(n, \theta)$, 即

$$P(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n.$$

- 假设 θ 的先验分布为 $U(0, 1)$. 贝叶斯假设: 同等无知原则。

- X 与 θ 的联合 (密度) 函数为:

$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, \dots, n, \quad 0 < \theta < 1.$$

- X 的边际分布为

$$m(X) = \binom{n}{x} \int_0^1 \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}.$$

- θ 的后验分布为 $\pi(\theta|x) = \frac{h(x|\theta)}{m(x)} = \frac{\Gamma(n+2)\theta^{x+1-1}(1-\theta)^{n-x+1-1}}{\Gamma(x+1)\Gamma(n-x+1)}.$

- $\theta|x \sim Be(x+1, n-x+1)$, $\hat{\theta} = E(\theta|x) = \frac{x+1}{n+2}$. 与 $\bar{x} = \frac{X}{n}$ 不同。

贝叶斯估计

- 总体为 $N(\mu, \sigma_0^2)$, 其中方差 σ_0^2 已知, μ 的先验分布为 $N(\theta, \tau^2)$, 其中的 θ 和 τ 均已知

贝叶斯估计

- 总体为 $N(\mu, \sigma_0^2)$, 其中方差 σ_0^2 已知, μ 的先验分布为 $N(\theta, \tau^2)$, 其中的 θ 和 τ 均已知

- X 与 μ 的联合分布:
$$h(X, \mu) = \frac{e^{-[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{2\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{2\tau^2}]}}{(2\pi)^{(n+1)/2} \tau \sigma_0^n}.$$

贝叶斯估计

- 总体为 $N(\mu, \sigma_0^2)$, 其中方差 σ_0^2 已知, μ 的先验分布为 $N(\theta, \tau^2)$, 其中的 θ 和 τ 均已知

- X 与 μ 的联合分布:
$$h(X, \mu) = \frac{e^{-[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{2\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{2\tau^2}]}}{(2\pi)^{(n+1)/2} \tau \sigma_0^n}.$$

- X 的边缘分布为 $m(X) = \int h(X, \mu) d\mu.$

- 后验分布为 $\pi(\mu|X) = \frac{h(X, \mu)}{m(X)} \sim N(\frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-1} + \tau^{-2}}).$

- 后验均值作为贝叶斯估计

$$\hat{\mu} = \frac{n/\sigma_0^2}{n/\sigma_0^2 + 1/\tau^2} \bar{x} + \frac{1/\tau^2}{n/\sigma_0^2 + 1/\tau^2} \theta.$$

贝叶斯估计

- 总体为 $N(\mu, \sigma_0^2)$, 其中方差 σ_0^2 已知, μ 的先验分布为 $N(\theta, \tau^2)$, 其中的 θ 和 τ 均已知

- X 与 μ 的联合分布:
$$h(X, \mu) = \frac{e^{-[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{2\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{2\tau^2}]}}{(2\pi)^{(n+1)/2} \tau \sigma_0^n}.$$

- X 的边缘分布为 $m(X) = \int h(X, \mu) d\mu.$

- 后验分布为 $\pi(\mu|X) = \frac{h(X, \mu)}{m(X)} \sim N(\frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-1} + \tau^{-2}}).$

- 后验均值作为贝叶斯估计

$$\hat{\mu} = \frac{n/\sigma_0^2}{n/\sigma_0^2 + 1/\tau^2} \bar{x} + \frac{1/\tau^2}{n/\sigma_0^2 + 1/\tau^2} \theta.$$

- 当 σ_0^2 越小, 样本的均值占的比重越大, 先验的方差 τ 越小, 先验的比重越大。

- 定义：设 θ 是总体分布 $p(x; \theta)$ 中的参数, $\pi(\theta)$ 是其先验分布, 如果对任意的来自总体 $p(x; \theta)$ 的样本观测值得到的后验分布 $\pi(\theta|X)$ 与 $\pi(\theta)$ 属于同一分布族 (类), 则称该分布族是 θ 的共轭先验分布族。

- 定义：设 θ 是总体分布 $p(x; \theta)$ 中的参数, $\pi(\theta)$ 是其先验分布, 如果对任意的来自总体 $p(x; \theta)$ 的样本观测值得到的后验分布 $\pi(\theta|X)$ 与 $\pi(\theta)$ 属于同一分布族 (类), 则称该分布族是 θ 的共轭先验分布族。
- 贝塔分布是伯努利试验中成功概率的共轭先验分布族:

共轭先验分布

- 定义：设 θ 是总体分布 $p(x; \theta)$ 中的参数, $\pi(\theta)$ 是其先验分布, 如果对任意的来自总体 $p(x; \theta)$ 的样本观测值得到的后验分布 $\pi(\theta|X)$ 与 $\pi(\theta)$ 属于同一分布族 (类), 则称该分布族是 θ 的共轭先验分布族。
- 贝塔分布是伯努利试验中成功概率的共轭先验分布族：均匀分布是 $Be(1, 1)$ 。

共轭先验分布

- 定义：设 θ 是总体分布 $p(x; \theta)$ 中的参数, $\pi(\theta)$ 是其先验分布, 如果对任意的来自总体 $p(x; \theta)$ 的样本观测值得到的后验分布 $\pi(\theta|X)$ 与 $\pi(\theta)$ 属于同一分布族 (类), 则称该分布族是 θ 的共轭先验分布族。
- 贝塔分布是伯努利试验中成功概率的共轭先验分布族: 均匀分布是 $Be(1, 1)$.
- 在方差已知时, 正态分布时正态总体均值的共轭先验分布族。